INFO1185 – INTELIGENCIA ARTIFICIAL

Detección de fraude

Aprendizaje supervisado en transacciones desbalanceadas

Fernando Alonso Valdés Gómez | Juan Francisco Muñoz Veloso

9 de octubre de 2026

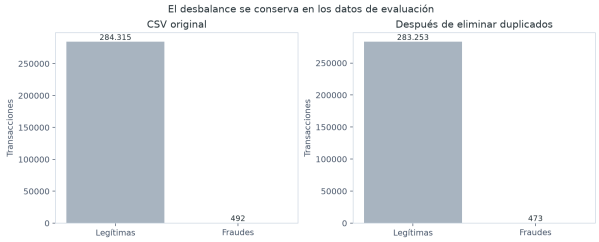
El reto

0,173 %

de las transacciones son fraude

Minimizar falsos negativos: evitar que un fraude pase como legítimo.

Los datos



284.807
transacciones

492
fraudes

30
variables predictoras

Tras quitar 1.081 duplicados exactos: 283.726 filas y 473 fraudes; sin valores faltantes.

Preparación y partición

70/30
partición estratificada · semilla 42

5 pliegues
búsqueda sobre 50.000 filas fijas

85.118
filas de prueba reservadas

Limpieza ⟶ Entrenamiento ⟶ Validación ⟶ Prueba

El test no interviene en la selección; el ganador se reajusta con 198.608 filas.

Escalado, selección y remuestreo se ajustan solo con el entrenamiento de cada pliegue; nunca con validación ni prueba.

Diseño experimental

4 modelos × 2 condiciones

8 experimentos

k-NN | Árbol de decisión | SVM lineal | Random Forest propio

Estándar
escalado para k-NN y SVM

ANOVA F
20 de 30 variables

1:10
submuestreo solo al entrenar

Random Forest propio

01
Bootstrap
Tamaño del train disponible, con reemplazo: pueden repetirse filas

→

02
Árboles de decisión
Independientes; $\lfloor \sqrt{p} \rfloor$ variables por división

→

03
Votación
Mayoría; empate = fraude

21 árboles · profundidad 6
Implementación del proyecto

Bagging combina árboles para reducir variabilidad; las variables aleatorias reducen su correlación. Semillas distintas, derivadas de la semilla general.

Selección del modelo

Criterio: maximizar sensibilidad media en cinco pliegues.
Desempate: mayor precisión de fraude.

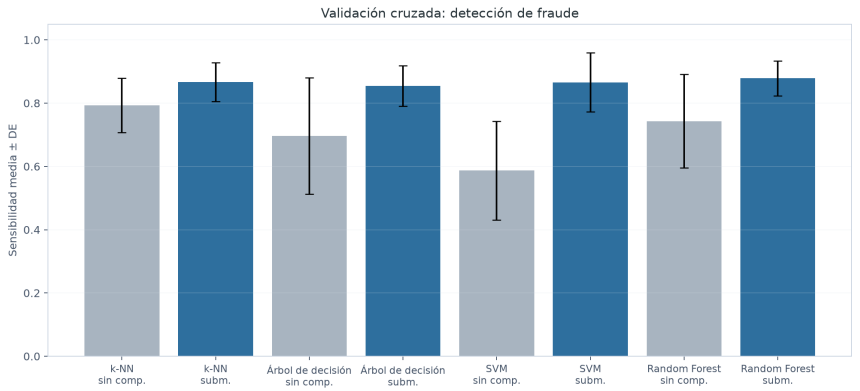
Random Forest propio + submuestreo 1:10

87,9 % ± 5,5 %
sensibilidad en validación

45,0 %
precisión en validación

Espacio de búsqueda: k-NN $k \in \{3, 5, 7\}$; árbol de decisión profundidad $\{5, 10, \text{libre}\}$ y hoja mínima $\{1, 5\}$; SVM lineal $C \in \{0{,}1;\ 1;\ 10\}$; Random Forest árboles $\{11, 21\}$ y profundidad $\{6, 12\}$.

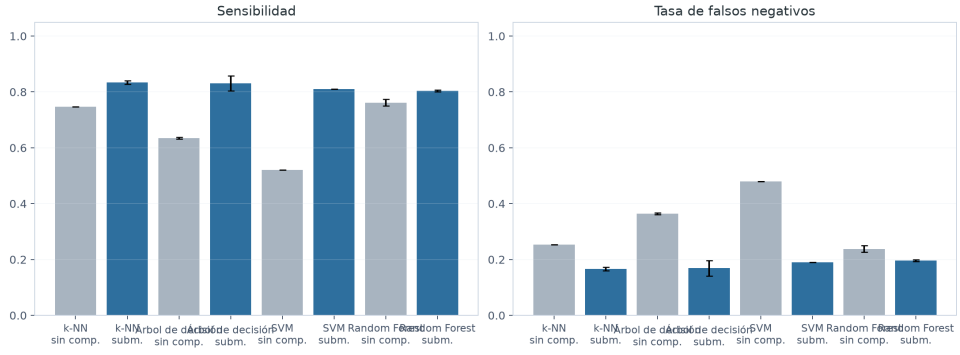
Validación cruzada



Sensibilidad de fraude · cinco pliegues compartidos

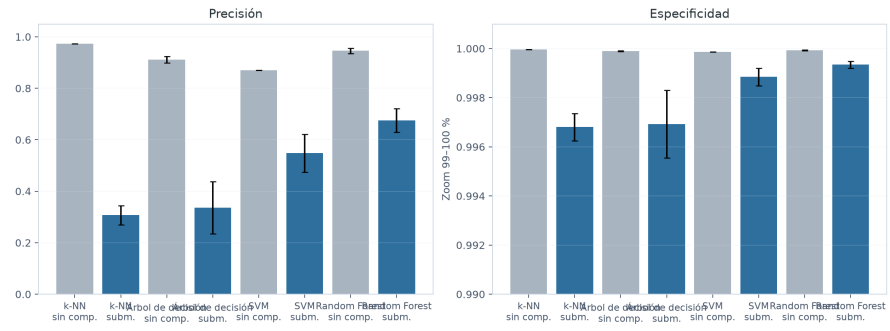
Prueba reservada

Problema Datos Preparación Modelos **Evaluación** Cierre



Mismo test fijo · media de cinco semillas

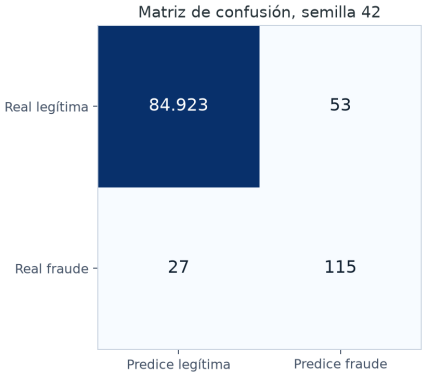
El costo de detectar más



Más sensibilidad también implica más falsas alarmas.

Árbol de decisión compensado: sensibilidad 83,1 %, precisión 33,6 %. Random Forest compensado: 80,4 % y 67,5 %. Random Forest genera menos alertas falsas, pero omite más fraudes.

Casos del modelo elegido



115
detectados

53
falsas alarmas

27
omitidos

84.923
legítimos reconocidos

Random Forest con submuestreo · primer ajuste de prueba · semilla 42

Cierre

80,4 %	19,6 %	67,5 %
sensibilidad	fraudes omitidos	precisión

Random Forest compensado detecta 4 de cada 5 fraudes.

La exactitud sola engaña: predecir todo como legítimo da 99,833 % y sensibilidad 0 %.

Límites: solo 142 fraudes de prueba, ANOVA marginal y grilla acotada; sin validación temporal.

Mejoras: más positivos y evaluar otro período con un test nuevo.

Respaldo · Validación

Cinco pliegues compartidos sobre una submuestra fija de 50.000 filas.

Modelo	Condición	Mejores parámetros	Sensibilidad ± DE	Precisión
k-NN	Sin compensar	$k = 3$	79,3 % ± 8,6 %	91,2 %
k-NN	Submuestreo	$k = 3$	86,6 % ± 6,1 %	37,5 %
Árbol de decisión	Sin compensar	profundidad 5; hoja 5	69,6 % ± 18,4 %	79,8 %
Árbol de decisión	Submuestreo	profundidad 5; hoja 5	85,4 % ± 6,4 %	18,6 %
SVM lineal	Sin compensar	$C = 10$	58,7 % ± 15,6 %	88,5 %
SVM lineal	Submuestreo	$C = 10$	86,5 % ± 9,3 %	21,2 %
Random Forest	Sin compensar	21 árboles; profundidad 12	74,3 % ± 14,7 %	91,6 %
Random Forest	**Submuestreo**	**21 árboles; profundidad 6**	**87,9 % ± 5,5 %**	**45,0 %**

Respaldo · Métricas de prueba

Media ± desviación estándar en puntos porcentuales entre cinco semillas sobre el mismo test fijo.

Modelo	Condición	Sens.	Espec.	Prec.	F1	Exact.	FNR
k-NN	Sin comp.	74,6 ± 0,0	99,996 ± 0,000	97,2 ± 0,0	84,5 ± 0,0	99,95 ± 0,00	25,4 ± 0,0
k-NN	Subm.	83,4 ± 0,6	99,681 ± 0,056	30,7 ± 3,7	44,8 ± 3,9	99,65 ± 0,06	16,6 ± 0,6
Árbol de decisión	Sin comp.	63,5 ± 0,3	99,990 ± 0,002	91,1 ± 1,2	74,9 ± 0,4	99,93 ± 0,00	36,5 ± 0,3
Árbol de decisión	Subm.	83,1 ± 2,7	99,692 ± 0,138	33,6 ± 10,1	47,0 ± 9,6	99,66 ± 0,13	16,9 ± 2,7
SVM	Sin comp.	52,1 ± 0,0	99,987 ± 0,000	87,1 ± 0,0	65,2 ± 0,0	99,91 ± 0,00	47,9 ± 0,0
SVM	Subm.	81,0 ± 0,0	99,885 ± 0,036	54,8 ± 7,4	65,2 ± 5,4	99,85 ± 0,04	19,0 ± 0,0
Random Forest	Sin comp.	76,2 ± 1,2	99,993 ± 0,002	94,6 ± 1,0	84,4 ± 0,6	99,95 ± 0,00	23,8 ± 1,2
Random Forest	**Subm.**	**80,4 ± 0,3**	**99,935 ± 0,014**	**67,5 ± 4,6**	**73,3 ± 2,8**	**99,90 ± 0,01**	**19,6 ± 0,3**

Respaldo · Metodología y búsqueda

Grid Search: mismos cinco pliegues y ocho condiciones; rangos prefijados, sin consultar prueba.

Modelo	Candidatos evaluados	Motivo
k-NN	Vecinos: 3, 5, 7 (pesos por distancia fijos)	Comparar vecindades locales y más suaves.
Árbol de decisión	Profundidad: 5, 10, libre; hoja mínima: 1, 5	Contrastar complejidad y hojas menos sensibles a pocos casos.
SVM lineal	C: 0,1; 1; 10	Comparar intensidad de regularización.
Random Forest	Árboles: 11, 21; profundidad: 6, 12; `max_features=sqrt`	Contrastar diversidad y complejidad con costo acotado.

Escalado estándar: evita que la magnitud domine distancias y regularización en k-NN/SVM; los árboles no lo requieren.

ANOVA F: selección estadística rápida de diferencias marginales entre clases; 20 variables prefijadas, sin un PCA nuevo. Puede perder interacciones.

Submuestreo 1:10: conserva los fraudes del entrenamiento y acota el costo; descarta información legítima. Validación y prueba conservan su prevalencia.

Respaldo · Árbol de decisión, Random Forest y falsas alarmas

Medias de cinco ajustes sobre el mismo test; se muestran las dos condiciones.

Modelo y condición	Sensibilidad	Precisión	Falsas alarmas
Árbol de decisión sin compensación	63,5 %	91,1 %	8,8
Random Forest sin compensación	76,2 %	94,6 %	6,2
Árbol de decisión compensado	83,1 %	33,6 %	261,6
Random Forest compensado	80,4 %	67,5 %	55,6

Random Forest mejora al árbol de decisión sin compensación. Con compensación intercambia sensibilidad por menos falsas alarmas; no garantiza superar al árbol de decisión en cada métrica. Se conserva el ganador de CV.

Todo legítimo: sensibilidad 0 %, FNR 100 %; la alta exactitud oculta el fraude.

Todo fraude: sensibilidad 100 %, FNR 0 %, especificidad 0 %; las 84.976 legítimas del test serían falsas alarmas. La prioridad de reducir falsos negativos se mantiene.