INFO1185 · INTELIGENCIA ARTIFICIAL

Detección de fraude

Aprendizaje supervisado en transacciones desbalanceadas

Fernando Alonso Valdés Gómez
Juan Francisco Muñoz Veloso

INFO1185 · Inteligencia Artificial · Octubre 2026

La exactitud oculta el error que más importa

En fraude, acertar la clase mayoritaria no equivale a proteger el sistema.

0,173 %
fraude en el dataset original

99,827 %
exactitud aparente

“Siempre legítimo”
0 % sensibilidad

OBJETIVO · Minimizar falsos negativos y maximizar sensibilidad en Class = 1

Datos reales, desbalance real

Credit Card Fraud Detection · Kaggle

284.807
filas originales · 492 fraudes

1.081
duplicados exactos

283.726
filas limpias · 473 fraudes

---

0 faltantes · 30 predictores · Class fuera de X
V1–V28 ya con PCA: no aplicamos uno nuevo.

Quitamos duplicados antes de dividir para evitar copias entre train y test.
Tras limpiar: 283.253 legítimas · 473 fraudes, el 0,167 %.

Primero separamos; después validamos

283.726

filas totales · partición
estratificada · semilla 42

ENTRENAMIENTO · 70 %
198.608 filas

Dentro de train: muestra de 50.000 filas.
Cada ronda: 40.000 aprenden; 10.000 validan.
Cinco rondas: el bloque de validación rota.
Después: reajuste con todo train.

TEST RESERVADO · 30 %
85.118 filas · 142 fraudes

El test queda fuera de los cinco pliegues.
Se evalúa al final, sin cambiar los parámetros.
La validación es interna al entrenamiento;
no hay un tercer conjunto fijo.

Cuatro métodos, con y sin submuestreo

Pipeline: escalado → submuestreo opcional → ANOVA → clasificador.
Escalado solo en k-NN/SVM. ANOVA elige 20 de 30 variables según diferencias entre clases.

SIN COMPENSAR	SUBMUESTREO 1:10
k-NN	k-NN
Árbol de decisión	Árbol de decisión
SVM lineal	SVM lineal
RF (Random Forest)	RF (Random Forest)

Ajuste final sin compensar: 198.608 filas llegan al clasificador.
Con 1:10: 331 fraudes + 3.310 legítimas = 3.641 filas.
Solo se reduce entrenamiento. Validación y test conservan sus filas.

k-NN: decide mirando casos cercanos

k = 3

Ejemplo didáctico: tres vecinos

VOTO LEGÍTIMO
Peso 10

Un vecino legítimo está a distancia 0,1.
Dos fraudes están a distancia 1 cada uno.
Con peso = 1/distancia, gana legítima.
Importa la cercanía, no solo contar votos.

VOTOS DE FRAUDE
Peso 1 + 1 = 2

En el principal probamos k = 3, 5 y 7.
Escalamos para comparar las distancias.
Un k mayor consulta más vecinos.
La elección se hace con validación.

Árbol de decisión: preguntar hasta clasificar

Cada pregunta divide los ejemplos. Una hoja da la predicción final.
Ejemplo didáctico: el umbral ilustrado no es una regla real del modelo.

PREGUNTA SOBRE UNA VARIABLE

¿V14 < −2?

Sí: una rama.

No: la otra rama.

LLEGAR A UNA HOJA

Puede hacer más preguntas.

La hoja predice:

0 legítima o 1 fraude.

Profundidad: cuántas preguntas puede encadenar. Más profundidad permite reglas más detalladas.
Hojas con pocos ejemplos pueden aprender casos demasiado específicos.
La búsqueda compara profundidad y mínimo de ejemplos por hoja para elegir con validación.

SVM lineal: aprender una frontera

El margen es una franja alrededor de la frontera. SVM intenta ampliarla, permitiendo errores.

LA IDEA

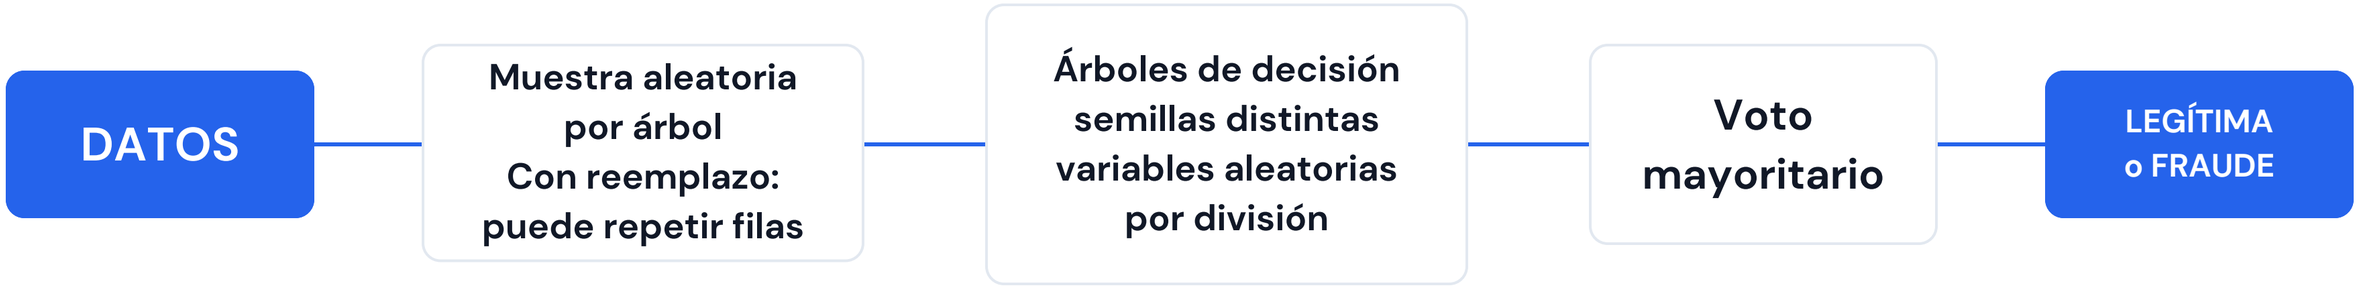
Una línea en dos dimensiones. Un plano en más dimensiones.

C

Probamos 0,1; 1 y 10.
Un C mayor penaliza más casos dentro del margen o al lado equivocado.
Se elige con validación.

RF (Random Forest): combinar varios árboles

Un árbol da una decisión. RF entrena árboles distintos y combina sus votos.



Ejemplo: 1, 0, 1 → fraude

Nuestro código organiza muestras, semillas y votación.
DecisionTreeClassifier construye cada árbol.
El ganador de CV usa 21 árboles y profundidad máxima 6.

El ejemplo de votos es didáctico. La implementación resuelve un empate como fraude.

ANOVA: elegir qué variables recibe el modelo

30 VARIABLES → 20 SELECCIONADAS

ANOVA examina una columna cada vez.
Compara las medias de las dos clases
con la dispersión dentro de cada clase.

Mayor puntuación F: mayor separación
relativa entre las medias.

F = variación media entre clases /
variación media dentro de clases

Se eligen las 20 mayores puntuaciones.
No crea variables nuevas ni prueba causas.
Puede perder relaciones entre columnas.

VARIABLE A · EJEMPLO DIDÁCTICO

Legítimas: 1, 2, 3
Fraudes: 8, 9, 10
Medias separadas: F alta.

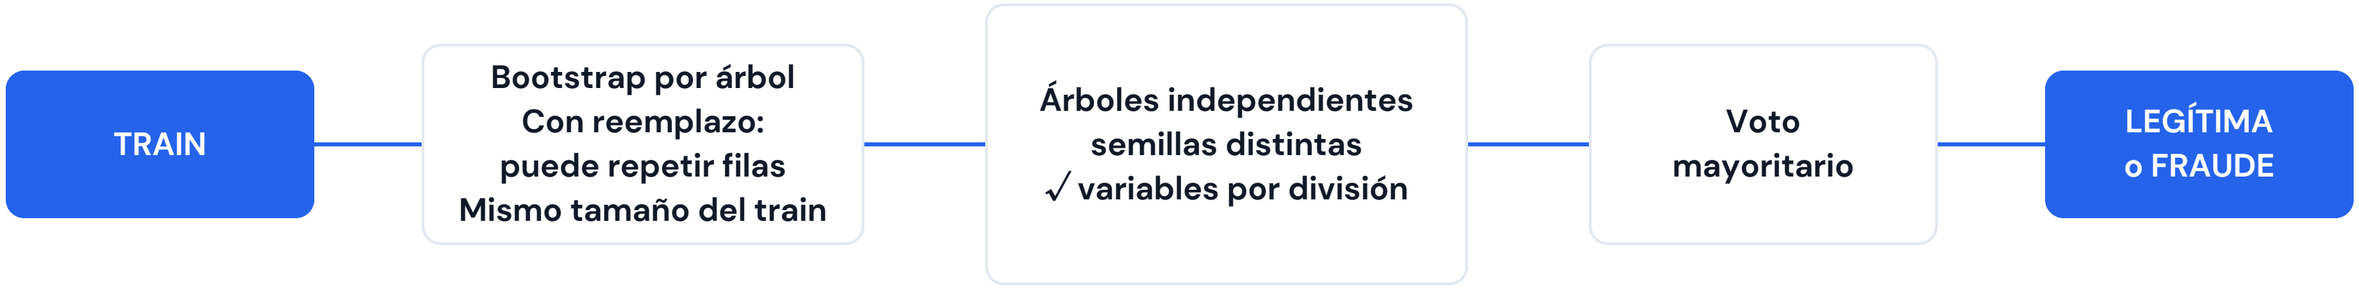
VARIABLE B · EJEMPLO DIDÁCTICO

Legítimas: 1, 5, 9
Fraudes: 2, 5, 8
Misma media: F = 0.

ANOVA se ajusta solo con entrenamiento.

RF: nuestra implementación

Bagging combina árboles para reducir variabilidad; elegir variables por división los diversifica.



EMPATE → FRAUDE

El bootstrap usa el train de cada condición,
submuestreado cuando corresponde.
Árbol base: DecisionTreeClassifier.

Configurable: número de árboles · profundidad · variables por división · semilla

GridSearchCV: elegir parámetros

Cada combinación se prueba en cinco rondas. Gana la mayor sensibilidad media; precisión desempata.

ESPACIO DE BÚSQUEDA

k-NN

3 · 5 · 7 vecinos | pesos por distancia

Árbol de decisión

Profundidad 5 · 10 · libre | hoja 1 · 5

SVM lineal

C = 0,1 · 1 · 10

RF (Random Forest)

11 · 21 árboles | profundidad 6 · 12

RF: max_features = √p en cada división

GANADOR

RF
con submuestreo

87,9 %

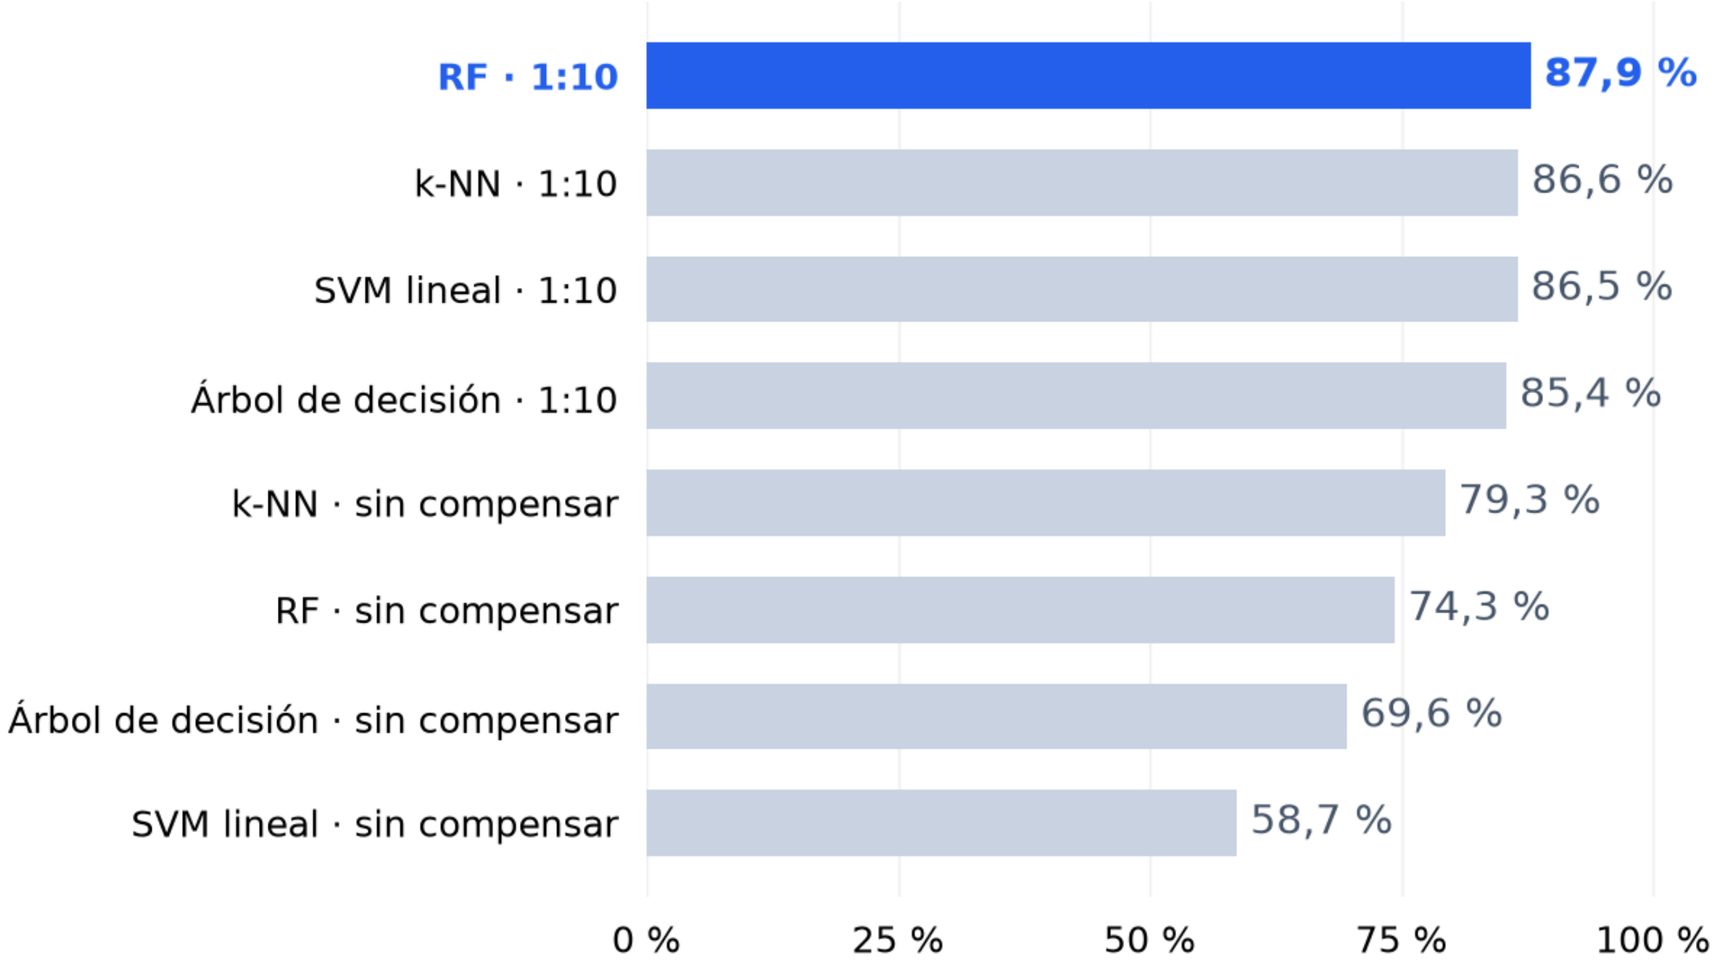
± 5,5 pp sensibilidad CV

45,0 % precisión

21 árboles · profundidad 6

Ganador en validación: RF con submuestreo

Comparamos sensibilidad media en cinco pliegues. El mayor valor elige al ganador antes de usar test.



GANADOR · RF 1:10

87,9 %

± 5,5 pp

Mayor media de detección en validación.

21 árboles
Profundidad máxima 6

± 5,5 pp describe variación entre pliegues.
No garantiza resultados futuros.

Evaluación final: cinco ajustes, un mismo test

Parámetros ya elegidos: reajustamos desde cero con semillas 42, 101, 202, 303 y 404.

MODELO	SIN COMPENSAR		SUBMUESTREO 1:10	
	Sensibilidad	FNR	Sensibilidad	FNR
k-NN	74,6 %	25,4 %	**83,4 %**	**16,6 %**
Árbol de decisión	63,5 %	36,5 %	**83,1 %**	**16,9 %**
SVM lineal	52,1 %	47,9 %	**81,0 %**	**19,0 %**
RF (Random Forest)	76,2 %	23,8 %	**80,4 %**	**19,6 %**

Cinco pliegues eligen parámetros; cinco semillas repiten el ajuste final. El test siempre es el mismo.

RF ganador: leer el resultado sin confundirlo

Elegido por validación. Estas métricas son medias de cinco ajustes sobre el mismo test.

67,5 %

PRECISIÓN

De las alertas, qué proporción era fraude.

19,6 %

FNR

De los fraudes, qué proporción se dejó pasar.

± 0,3 pp

VARIACIÓN

Dispersión de sensibilidad entre cinco ajustes.

80,4 %

SENSIBILIDAD

Aproximadamente 8 de cada 10 fraudes detectados.

Sensibilidad y precisión responden preguntas distintas. Alta detección no significa que toda alerta sea fraude.

Detectar más también puede costar más

Sensibilidad: fraudes detectados / fraudes reales. Precisión: fraudes / alertas emitidas.

Árbol de decisión sin compensación	RF sin compensación	Árbol de decisión submuestreo 1:10	RF submuestreo 1:10
63,5 % sensibilidad	76,2 % sensibilidad	83,1 % sensibilidad	80,4 % sensibilidad
91,1 % precisión	94,6 % precisión	33,6 % precisión	67,5 % precisión
8,8 FP	6,2 FP	261,6 FP	55,6 FP

Compensado: el RF omite más fraudes que el árbol, pero reduce falsas alarmas. Conservamos el ganador de CV.

El ganador detecta 115 de 142 fraudes

RF con submuestreo · semilla 42 · un ajuste individual sobre test

	Pred. legítima	Pred. fraude
Real legítima	TN 84.923	FP 53
Real fraude	FN 27	TP 115

Este ajuste: 115 / 142 = 81,0 % de sensibilidad.
La media de cinco ajustes es 80,4 %.

RF ganador: detecta cerca de 4 de cada 5 fraudes

80,4 %

Sensibilidad en prueba · ± 0,3 pp

RF (RANDOM FOREST) · SUBMUESTREO 1:10
21 árboles · profundidad 6

FNR 19,6 % ± 0,3 pp
Precisión 67,5 % ± 4,6 pp

LÍMITES DEL ESTUDIO

142 fraudes en prueba
ANOVA: relaciones marginales
Grilla de búsqueda acotada
Sin validación temporal

SIGUIENTE PASO

Más positivos y un nuevo período con un test adicional.

Respaldo · Parámetros y CV

Sensibilidad ± DE en pp; precisión en fraude.

Ocho condiciones · parámetros elegidos · sensibilidad y precisión de fraude

kNN · Sin compensar | k=3 | Sens. 79,3 % ± 8,6 pp | Prec. 91,2 %
kNN · Submuestreo | k=3 | Sens. 86,6 % ± 6,1 pp | Prec. 37,5 %
Árbol de decisión · Sin compensar | prof. 5; hoja 5 | Sens. 69,6 % ± 18,4 pp | Prec. 79,8 %
Árbol de decisión · Submuestreo | prof. 5; hoja 5 | Sens. 85,4 % ± 6,4 pp | Prec. 18,6 %
SVM · Sin compensar | C=10 | Sens. 58,7 % ± 15,6 pp | Prec. 88,5 %
SVM · Submuestreo | C=10 | Sens. 86,5 % ± 9,3 pp | Prec. 21,2 %
RF · Sin compensar | 21 árboles; prof. 12 | Sens. 74,3 % ± 14,7 pp | Prec. 91,6 %
RF · Submuestreo | 21 árboles; prof. 6 | Sens. 87,9 % ± 5,5 pp | Prec. 45,0 %

Ocho condiciones · parámetros elegidos sin mirar el test.

Respaldo · Métricas sin compensación

Métricas en % · media ± DE en pp · cinco semillas sobre el mismo test.

Sensibilidad · Especificidad · Precisión · F1 · Exactitud · FNR

kNN · Sens. 74,6±0,0 · Espec. 99,996±0,000 · Prec. 97,2±0,0
F1 84,5±0,0 · Exact. 99,95±0,00 · FNR 25,4±0,0

Árbol de decisión · Sens. 63,5±0,3 · Espec. 99,990±0,002 · Prec. 91,1±1,2
F1 74,9±0,4 · Exact. 99,93±0,00 · FNR 36,5±0,3

SVM · Sens. 52,1±0,0 · Espec. 99,987±0,000 · Prec. 87,1±0,0
F1 65,2±0,0 · Exact. 99,91±0,00 · FNR 47,9±0,0

RF · Sens. 76,2±1,2 · Espec. 99,993±0,002 · Prec. 94,6±1,0
F1 84,4±0,6 · Exact. 99,95±0,00 · FNR 23,8±1,2

La exactitud permanece alta por el fuerte desbalance; no es el criterio de selección.

Respaldo · Métricas con compensación

Métricas en % · media ± DE en pp · submuestreo 1:10 · test fijo.

Sensibilidad · Especificidad · Precisión · F1 · Exactitud · FNR

kNN · Sens. 83,4±0,6 · Espec. 99,681±0,056 · Prec. 30,7±3,7
F1 44,8±3,9 · Exact. 99,65±0,06 · FNR 16,6±0,6

Árbol de decisión · Sens. 83,1±2,7 · Espec. 99,692±0,138 · Prec. 33,6±10,1
F1 47,0±9,6 · Exact. 99,66±0,13 · FNR 16,9±2,7

SVM · Sens. 81,0±0,0 · Espec. 99,885±0,036 · Prec. 54,8±7,4
F1 65,2±5,4 · Exact. 99,85±0,04 · FNR 19,0±0,0

RF · Sens. 80,4±0,3 · Espec. 99,935±0,014 · Prec. 67,5±4,6
F1 73,3±2,8 · Exact. 99,90±0,01 · FNR 19,6±0,3

El RF compensado retiene la mejor precisión entre las alternativas submuestreadas.

Respaldo · Decisiones y extremos

CRITERIOS DE BÚSQUEDA

k-NN · Vecindad y suavidad
Árbol de decisión · Profundidad y hojas
SVM · Regularización C
RF · Diversidad y costo

CONTROLES DEL PROTOCOLO

ANOVA: 20 variables prefijadas.
V1–V28 ya con PCA; no aplicamos otro.
Bootstrap: muestreo con reemplazo.
Semillas 42 · 101 · 202 · 303 · 404.
Mismo test: variación de cinco ajustes.

SIEMPRE LEGÍTIMO

0 % sensibilidad
FNR 100 %
Exactitud 99,833 %

SIEMPRE FRAUDE

84.976 falsas alarmas
Sensibilidad 100 %
Especificidad 0 %

No confundir estos extremos con el RF ganador.