INFO1185 · INTELIGENCIA ARTIFICIAL

Detección de fraude

Aprendizaje supervisado en transacciones desbalanceadas

Fernando Alonso Valdés Gómez
Juan Francisco Muñoz Veloso

INFO1185 · Inteligencia Artificial · Octubre 2026

La exactitud oculta el error que más importa

En fraude, acertar la clase mayoritaria no equivale a proteger el sistema.

0,173 %
fraude en el dataset original

99,827 %
exactitud aparente

“Siempre legítimo”
0 % sensibilidad

OBJETIVO · Minimizar falsos negativos y maximizar sensibilidad en Class = 1

Datos reales, desbalance real

Credit Card Fraud Detection · Kaggle

284.807
filas originales · 492 fraudes

1.081
duplicados exactos

283.726
filas limpias · 473 fraudes

---

0 faltantes · 30 predictores · Class fuera de X
V1–V28 ya con PCA: no aplicamos uno nuevo.

Time · Amount · V1–V28
Limpieza antes de particionar.

Un test reservado de principio a fin

283.726

filas totales · partición
estratificada · semilla 42

70 % TRAIN
198.608 filas

CV estratificada · 5 pliegues
Submuestra fija: 50.000 filas · 83 fraudes
Misma base para ocho experimentos

30 % TEST
85.118 filas · 142 fraudes

RESERVADO
Sin influencia sobre variables, modelos o umbral

Ocho experimentos, una comparación justa

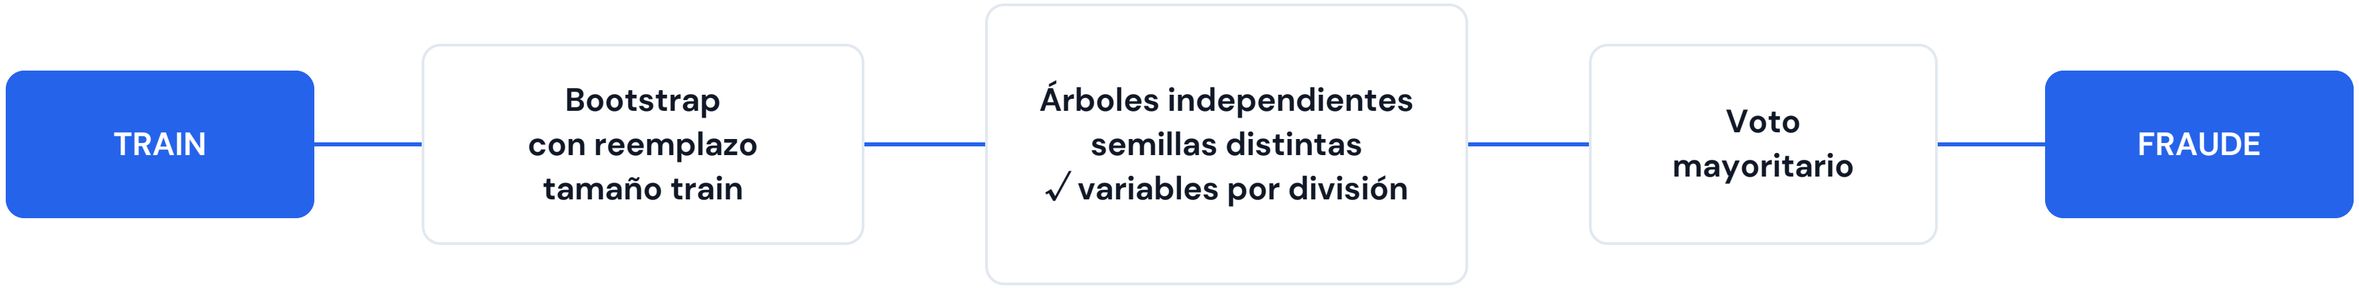
Escalado para distancias y regularización · ANOVA F rápido y marginal.
Todas las transformaciones se ajustan solo con el train de cada pliegue.

SIN COMPENSAR	SUBMUESTREO 1:10
k-NN	k-NN
Árbol de decisión	Árbol de decisión
SVM lineal	SVM lineal
Bosque propio	Bosque propio

Top 20 prefijado · El submuestreo conserva fraudes y reduce costo, pero pierde legítimas.
Validación y prueba mantienen su distribución original.

Un bosque construido por nosotros

Bagging reduce variabilidad; max_features aleatorio por división reduce correlación.



EMPATE → FRAUDE

fit y predict permanecen separados

Configurable: número de árboles · profundidad · variables por división · semilla

Elegir sin mirar prueba

Maximizar sensibilidad media en CV; desempatar por precisión en fraude.

ESPACIO DE BÚSQUEDA

k-NN

3 · 5 · 7 vecinos | pesos por distancia

Árbol de decisión

Profundidad 5 · 10 · libre | hoja 1 · 5

SVM lineal

C = 0,1 · 1 · 10

Bosque propio

11 · 21 árboles | profundidad 6 · 12

Bosque: max_features = √p en cada división

GANADOR

Bosque compensado

87,9 %

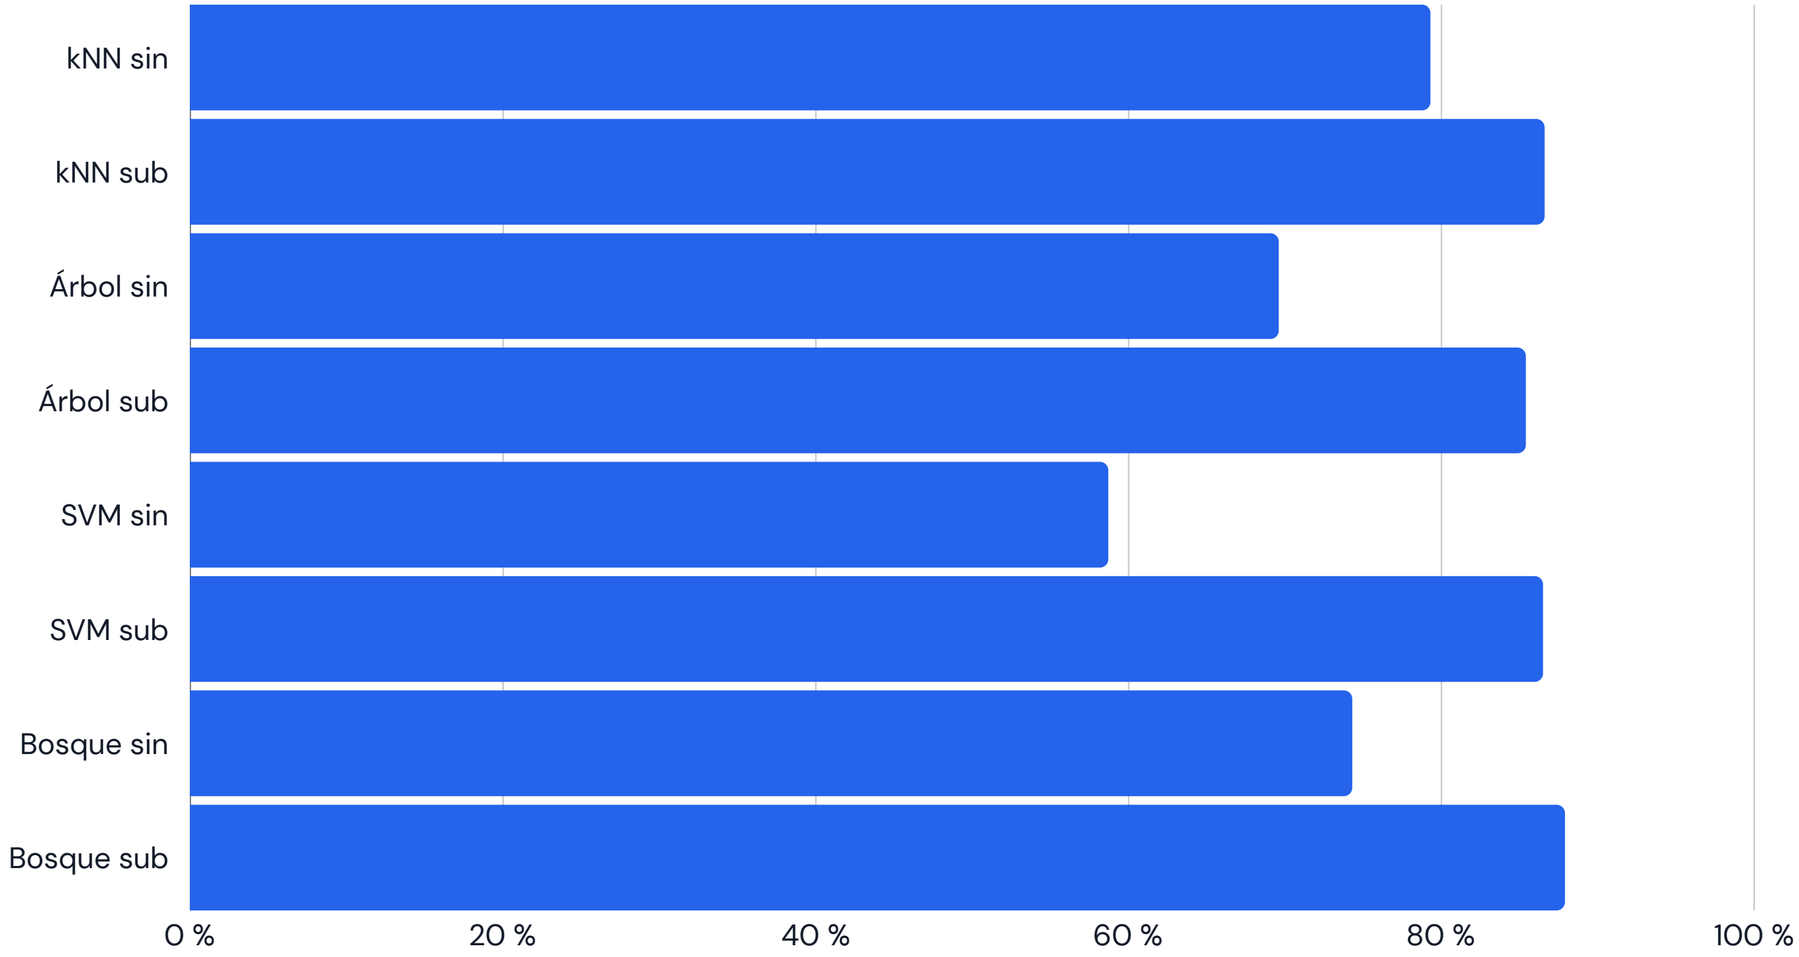
± 5,5 pp sensibilidad CV

45,0 % precisión

21 árboles · profundidad 6

El bosque compensado lidera en validación

Sensibilidad media; variabilidad expresada como desviación estándar en puntos porcentuales.



MEJOR RESULTADO

87,9 %

± 5,5 pp

DE (pp)
8,6 · 6,1
18,4 · 6,4
15,6 · 9,3
14,7 · 5,5

La prueba reservada confirma el intercambio

Cinco reajustes sobre el mismo test · semillas 42, 101, 202, 303 y 404

MODELO	SIN COMPENSAR		SUBMUESTREO 1:10	
	Sensibilidad	FNR	Sensibilidad	FNR
k-NN	74,6 %	25,4 %	**83,4 %**	**16,6 %**
Árbol	63,5 %	36,5 %	**83,1 %**	**16,9 %**
SVM lineal	52,1 %	47,9 %	**81,0 %**	**19,0 %**
Bosque propio	76,2 %	23,8 %	**80,4 %**	**19,6 %**

La DE mide variación del ajuste, no cinco tests independientes. El ganador no se cambia mirando test.

Detectar más también puede costar más

Más sensibilidad puede comprar demasiadas falsas alarmas.

Árbol sin	Bosque sin	Árbol 1:10	Bosque 1:10
63,5 % sensibilidad	76,2 % sensibilidad	83,1 % sensibilidad	80,4 % sensibilidad
91,1 % precisión	94,6 % precisión	33,6 % precisión	67,5 % precisión
8,8 FP	6,2 FP	261,6 FP	55,6 FP

Compensado: el bosque omite más fraudes que el árbol, pero reduce falsas alarmas. Conservamos el ganador de CV.

El ganador detecta 115 de 142 fraudes

Bosque compensado · semilla 42 · un ajuste individual sobre test

	Pred. legítima	Pred. fraude
Real legítima	TN 84.923	FP 53
Real fraude	FN 27	TP 115

TOTAL TEST · 85.118 FILAS

Cuatro de cada cinco fraudes, detectados

80,4 %

Sensibilidad en prueba · ± 0,3 pp

BOSQUE COMPENSADO 1:10
21 árboles · profundidad 6

FNR 19,6 % ± 0,3 pp
Precisión 67,5 % ± 4,6 pp

LÍMITES DEL ESTUDIO

142 fraudes en prueba
ANOVA: relaciones marginales
Grilla de búsqueda acotada
Sin validación temporal

SIGUIENTE PASO

Más positivos y un nuevo período con un test adicional.

Respaldo · Parámetros y CV

Sensibilidad ± DE en pp; precisión en fraude.

Ocho condiciones · parámetros elegidos · sensibilidad y precisión de fraude

kNN · Sin compensar | k=3 | Sens. 79,3 % ± 8,6 pp | Prec. 91,2 %
kNN · Submuestreo | k=3 | Sens. 86,6 % ± 6,1 pp | Prec. 37,5 %
Árbol · Sin compensar | prof. 5; hoja 5 | Sens. 69,6 % ± 18,4 pp | Prec. 79,8 %
Árbol · Submuestreo | prof. 5; hoja 5 | Sens. 85,4 % ± 6,4 pp | Prec. 18,6 %
SVM · Sin compensar | C=10 | Sens. 58,7 % ± 15,6 pp | Prec. 88,5 %
SVM · Submuestreo | C=10 | Sens. 86,5 % ± 9,3 pp | Prec. 21,2 %
Bosque · Sin compensar | 21 árboles; prof. 12 | Sens. 74,3 % ± 14,7 pp | Prec. 91,6 %
Bosque · Submuestreo | 21 árboles; prof. 6 | Sens. 87,9 % ± 5,5 pp | Prec. 45,0 %

Ocho condiciones · parámetros elegidos sin mirar el test.

Respaldo · Métricas sin compensación

Métricas en % · media ± DE en pp · cinco semillas sobre el mismo test.

Sensibilidad · Especificidad · Precisión · F1 · Exactitud · FNR

kNN · Sens. 74,6±0,0 · Espec. 99,996±0,000 · Prec. 97,2±0,0
F1 84,5±0,0 · Exact. 99,95±0,00 · FNR 25,4±0,0

Árbol · Sens. 63,5±0,3 · Espec. 99,990±0,002 · Prec. 91,1±1,2
F1 74,9±0,4 · Exact. 99,93±0,00 · FNR 36,5±0,3

SVM · Sens. 52,1±0,0 · Espec. 99,987±0,000 · Prec. 87,1±0,0
F1 65,2±0,0 · Exact. 99,91±0,00 · FNR 47,9±0,0

Bosque · Sens. 76,2±1,2 · Espec. 99,993±0,002 · Prec. 94,6±1,0
F1 84,4±0,6 · Exact. 99,95±0,00 · FNR 23,8±1,2

La exactitud permanece alta por el fuerte desbalance; no es el criterio de selección.

Respaldo · Métricas con compensación

Métricas en % · media ± DE en pp · submuestreo 1:10 · test fijo.

Sensibilidad · Especificidad · Precisión · F1 · Exactitud · FNR

kNN · Sens. 83,4±0,6 · Espec. 99,681±0,056 · Prec. 30,7±3,7
F1 44,8±3,9 · Exact. 99,65±0,06 · FNR 16,6±0,6

Árbol · Sens. 83,1±2,7 · Espec. 99,692±0,138 · Prec. 33,6±10,1
F1 47,0±9,6 · Exact. 99,66±0,13 · FNR 16,9±2,7

SVM · Sens. 81,0±0,0 · Espec. 99,885±0,036 · Prec. 54,8±7,4
F1 65,2±5,4 · Exact. 99,85±0,04 · FNR 19,0±0,0

Bosque · Sens. 80,4±0,3 · Espec. 99,935±0,014 · Prec. 67,5±4,6
F1 73,3±2,8 · Exact. 99,90±0,01 · FNR 19,6±0,3

El bosque compensado retiene la mejor precisión entre las alternativas submuestreadas.

Respaldo · Decisiones y extremos

CRITERIOS DE BÚSQUEDA

k-NN · Vecindad y suavidad
Árbol · Profundidad y hojas
SVM · Regularización C
Bosque · Diversidad y costo

CONTROLES DEL PROTOCOLO

ANOVA: 20 variables prefijadas.
V1–V28 ya con PCA; no aplicamos otro.
Bootstrap: muestreo con reemplazo.
Semillas 42 · 101 · 202 · 303 · 404.
Mismo test: variación de cinco ajustes.

SIEMPRE LEGÍTIMO

0 % sensibilidad
FNR 100 %
Exactitud 99,833 %

SIEMPRE FRAUDE

84.976 falsas alarmas
Sensibilidad 100 %
Especificidad 0 %

No confundir estos extremos con el bosque ganador.