Detectar fraude con aprendizaje supervisado

Comparación de ocho condiciones con sensibilidad como criterio principal

99,827%

exactitud al predecir todo legítimo

0%

sensibilidad para fraude

Fernando Alonso Valdés Gómez

Juan Francisco Muñoz Veloso

CONTEXTO

La exactitud puede ocultar el fraude

La clase positiva es la transacción fraudulenta.

99,827%

Exactitud base

284.315 de 284.807 filas son legítimas.

0%

Sensibilidad base

Predecir siempre legítimo omite los 492 fraudes.

Objetivo

Encontrar más fraude y vigilar falsas alarmas.

La evaluación prioriza sensibilidad. La precisión muestra cuántas alertas corresponden a fraude.

Una clase rara y duplicados exactos

Credit Card Fraud Detection · CSV inspeccionado antes del modelado.

284.807

filas originales

492

fraudes originales

0,173% de las filas.

1.081

duplicados exactos

283.726

filas tras limpieza

30 predictores: Time, Amount y V1–V28

Class excluida · 0 faltantes · 473 fraudes tras limpiar. Se quitan duplicados antes de separar train y test.

No aplicamos nuevo PCA.

V1–V28 ya son componentes del dataset.

Particiones fijas y prueba reservada

La selección se hace en train. El test se usa al final.

TRAIN · 70% estratificado · semilla 42

198.608 filas

Submuestra: 50.000 · 83 fraudes

TEST · 30% estratificado · reservado

85.118 filas

142 fraudes · 84.976 legítimas

Validación cruzada estratificada de 5 pliegues. Los ocho experimentos comparten los mismos pliegues.

Búsqueda con 50.000 filas; reajuste final sobre las 198.608 filas de entrenamiento, con el submuestreo correspondiente a cada condición.

MÉTODO

Ocho condiciones, una comparación controlada

Dos condiciones: sin compensación y submuestreo de 1 fraude por cada 10 legítimas.

Clasificador	Condiciones	Transformación
k-NN	Sin compensación · submuestreo 1:10	StandardScaler · ANOVA F top 20
Árbol de decisión	Sin compensación · submuestreo 1:10	ANOVA F top 20
SVM lineal	Sin compensación · submuestreo 1:10	StandardScaler · ANOVA F top 20
Random Forest propio	Sin compensación · submuestreo 1:10	ANOVA F top 20

Cada transformación y remuestreo se ajusta solo con el train de cada pliegue: sin fuga de información.

Seleccionamos las 20 variables con mayor puntuación ANOVA F, un criterio marginal. El submuestreo conserva fraudes, pero descarta legítimas. Escalar importa para distancias y regularización.

Bosque propio: árboles diversos por bootstrap

Número de árboles, profundidad, max_features y semilla configurables; el ganador usa 21 árboles y profundidad 6.

01

Bootstrap

Muestra con reemplazo, del tamaño del train de cada condición; ya submuestreado cuando corresponde.

02

Árbol diverso

Semillas distintas derivadas de la semilla general; max_features='sqrt' en cada división.

03

Legítima o fraude

predict suma los votos de los árboles; el empate favorece fraude. fit y predict están separados.

Bagging reduce la variabilidad; max_features por división reduce la correlación entre árboles.

SELECCIÓN

La búsqueda prioriza sensibilidad y desempata por precisión

Grillas acotadas por costo; C se muestra con coma decimal.

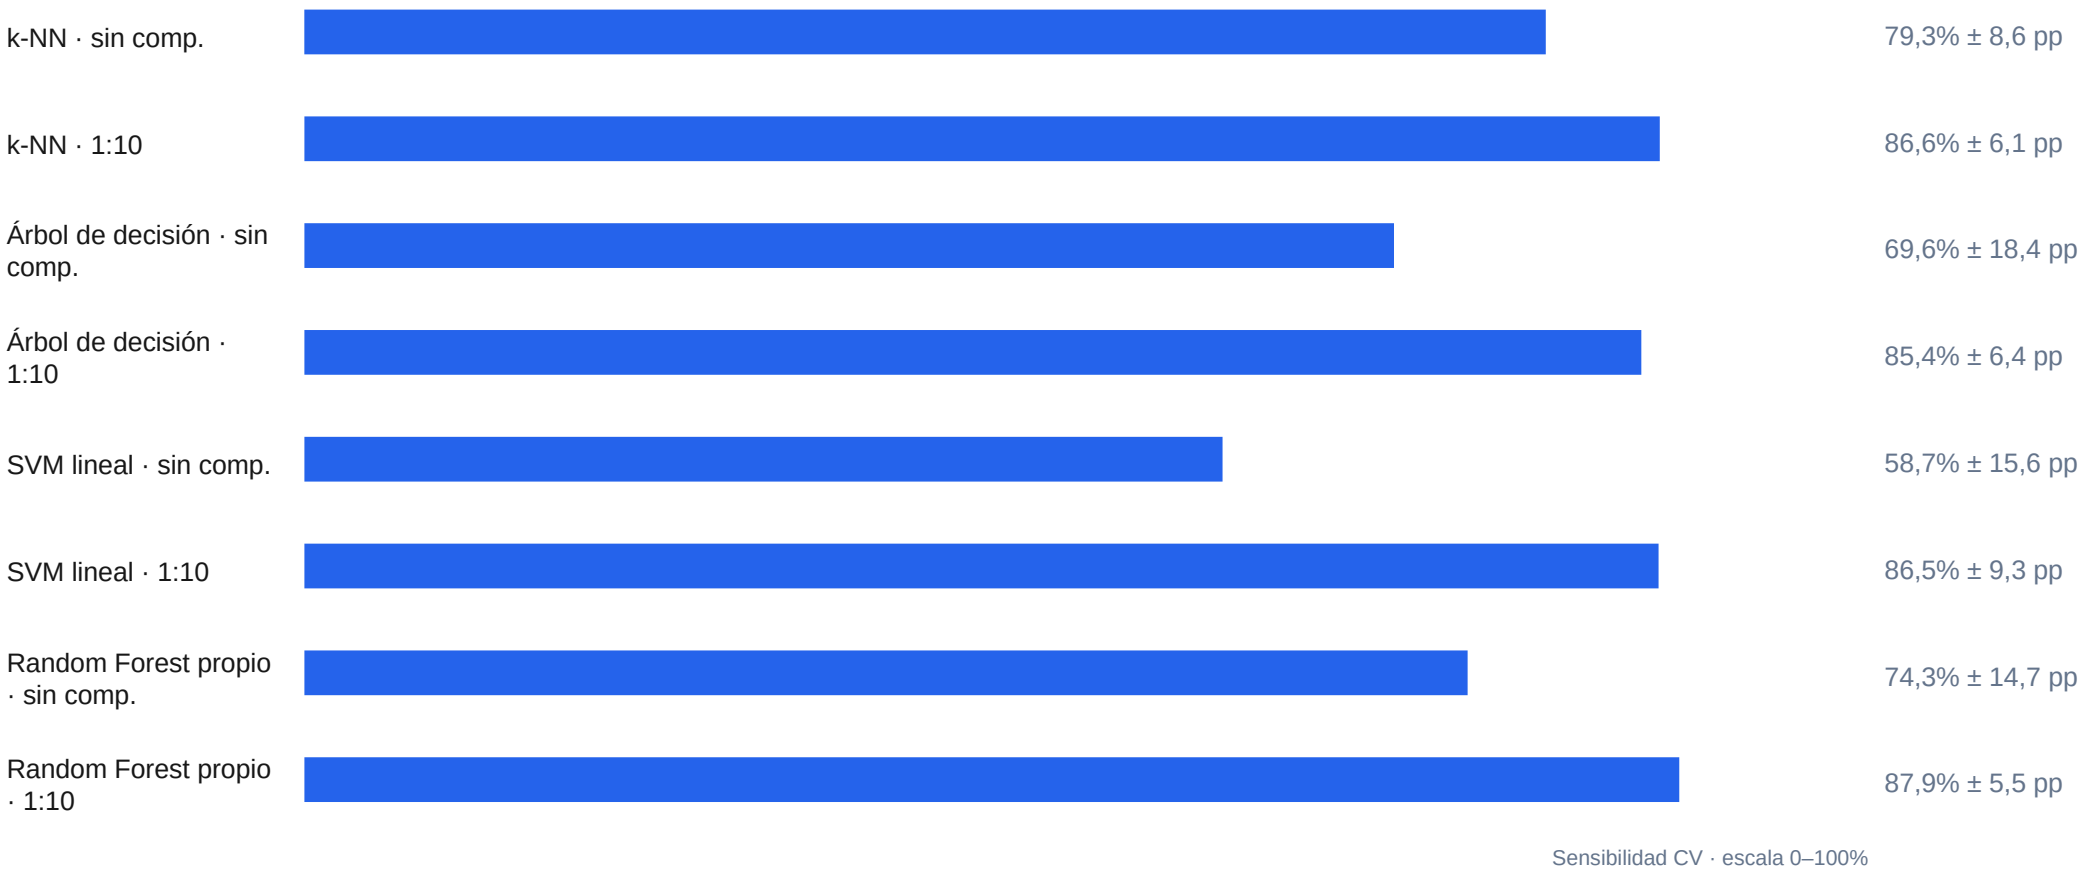
Modelo	Valores explorados
k-NN	n_neighbors: 3/5/7
Árbol de decisión	max_depth: 5/10/libre; min_samples_leaf: 1/5
SVM lineal	C: 0,1/1/10
Random Forest propio	n_estimators: 11/21; max_depth: 6/12

Ganador CV: Random Forest propio con submuestreo 1:10 · max_depth=6, n_estimators=21 · sensibilidad 87,9% ± 5,5 pp

Vecinos: suavidad; profundidad y hojas: complejidad; C: regularización; árboles: diversidad y costo. Pesos por distancia fijos en k-NN.

La sensibilidad más alta aparece con el bosque compensado

Media ± desviación estándar entre los 5 pliegues.



Mayor media observada; no demuestra superioridad estadística. La precisión desempata.

La sensibilidad final se estima con cinco reajustes

Mismo conjunto de prueba en cada repetición; se muestran sensibilidad y FNR.



Medias en %; desviaciones estándar en puntos porcentuales (pp).

Árbol y bosque muestran el costo de recuperar fraude

Promedios en test; falsas alarmas por repetición.

Condición	Sensibilidad	Precisión	FP promedio
Árbol de decisión · sin comp.	63,5%	91,1%	8,8
Árbol de decisión · 1:10	83,1%	33,6%	261,6
Random Forest propio · sin comp.	76,2%	94,6%	6,2
Random Forest propio · 1:10	80,4%	67,5%	55,6

Con 1:10, el bosque tiene menor sensibilidad que el árbol, pero menos FP.

El ganador se mantuvo según CV; no se cambió tras mirar el test.

Matriz de confusión del ganador en un ajuste

Predicciones guardadas para la configuración elegida por CV.

	Predicción legítimo	Predicción fraude
Real legítimo	**84.923** TN	**53** FP
Real fraude	**27** FN	**115** TP

Captura 115 de 142 fraudes; genera 53 falsas alarmas.

Una sola semilla explica la matriz; el resumen final promedia cinco semillas.

Ganador seleccionado por validación: bosque con submuestreo

La selección se fijó antes de consultar el test.

87,9% ± 5,5 pp

Sensibilidad CV

Media ± DE · 5 pliegues.

80,4% ± 0,3 pp

Sensibilidad test

Media ± DE · cinco reajustes.

67,5% ± 4,6 pp

Precisión test

Alertas que son fraude.

19,6% ± 0,3 pp

FNR test

Fracción de fraude omitido.

Límites

Test con 142 fraudes; las cinco repeticiones comparten los casos. ANOVA F es marginal, la grilla es acotada y no se hizo validación temporal.

Parámetros y métricas CV de los ocho experimentos

Medias en %; desviaciones estándar en pp. `weights=distance` se mantiene fijo en k-NN.

Modelo	Muestreo	Mejores parámetros	Sens. CV	Prec. CV
k-NN	Ninguna	n_neighbors=3	79,3% ± 8,6 pp	91,2%
k-NN	1:10	n_neighbors=3	86,6% ± 6,1 pp	37,5%
Árbol de decisión	Ninguna	max_depth=5, min_samples_leaf=5	69,6% ± 18,4 pp	79,8%
Árbol de decisión	1:10	max_depth=5, min_samples_leaf=5	85,4% ± 6,4 pp	18,6%
SVM lineal	Ninguna	C=10	58,7% ± 15,6 pp	88,5%
SVM lineal	1:10	C=10	86,5% ± 9,3 pp	21,2%
Random Forest propio	Ninguna	max_depth=12, n_estimators=21	74,3% ± 14,7 pp	91,6%
Random Forest propio	1:10	max_depth=6, n_estimators=21	87,9% ± 5,5 pp	45,0%

Seis métricas · Sin compensación

Media en % ± desviación estándar en pp · cinco reajustes sobre el mismo test.

Modelo	Sens.	Espec.	Prec.	F1	Exact.	FNR
k-NN	74,6% ± 0,0 pp	99,996% ± 0,000 pp	97,2% ± 0,0 pp	84,5% ± 0,0 pp	99,95% ± 0,00 pp	25,4% ± 0,0 pp
Árbol de decisión	63,5% ± 0,3 pp	99,990% ± 0,002 pp	91,1% ± 1,2 pp	74,9% ± 0,4 pp	99,93% ± 0,00 pp	36,5% ± 0,3 pp
SVM lineal	52,1% ± 0,0 pp	99,987% ± 0,000 pp	87,1% ± 0,0 pp	65,2% ± 0,0 pp	99,91% ± 0,00 pp	47,9% ± 0,0 pp
Random Forest propio	76,2% ± 1,2 pp	99,993% ± 0,002 pp	94,6% ± 1,0 pp	84,4% ± 0,6 pp	99,95% ± 0,00 pp	23,8% ± 1,2 pp

Espec. con 3 decimales y exactitud con 2 para no ocultar FP; DE en puntos porcentuales.

Seis métricas · Con submuestreo 1:10

Media en % ± desviación estándar en pp · cinco reajustes sobre el mismo test.

Modelo	Sens.	Espec.	Prec.	F1	Exact.	FNR
k-NN	83,4% ± 0,6 pp	99,681% ± 0,056 pp	30,7% ± 3,7 pp	44,8% ± 3,9 pp	99,65% ± 0,06 pp	16,6% ± 0,6 pp
Árbol de decisión	83,1% ± 2,7 pp	99,692% ± 0,138 pp	33,6% ± 10,1 pp	47,0% ± 9,6 pp	99,66% ± 0,13 pp	16,9% ± 2,7 pp
SVM lineal	81,0% ± 0,0 pp	99,885% ± 0,036 pp	54,8% ± 7,4 pp	65,2% ± 5,4 pp	99,85% ± 0,04 pp	19,0% ± 0,0 pp
Random Forest propio	80,4% ± 0,3 pp	99,935% ± 0,014 pp	67,5% ± 4,6 pp	73,3% ± 2,8 pp	99,90% ± 0,01 pp	19,6% ± 0,3 pp

Espec. con 3 decimales y exactitud con 2 para no ocultar FP; DE en puntos porcentuales.

Dos reglas simples muestran el costo del desbalance

Cálculos sobre el test principal, con 84.976 legítimas y 142 fraudes.

Siempre legítimo

Exactitud 99,833% · sensibilidad 0%

142 fraudes omitidos

Siempre fraude

Sensibilidad 100% · especificidad 0%

84.976 falsas alarmas

Por qué se busca sensibilidad

El costo de omitir fraude puede ser alto; la precisión y los FP miden la carga de revisión.

Siguientes mejoras

Probar umbrales, calibración, validación temporal y nuevos datos solo con un test nuevo y separado.