INFO1185 – INTELIGENCIA ARTIFICIAL

Detección de fraude

Aprendizaje supervisado en transacciones desbalanceadas

Fernando Valdés Gomez | Juan Muñoz Veloso

9 de octubre de 2026

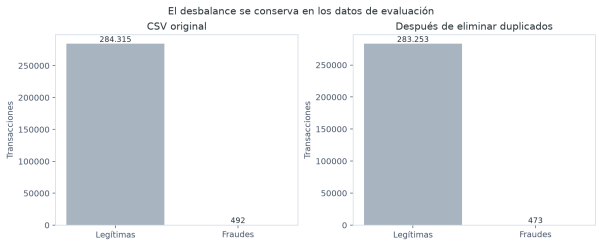
El reto

0,173 %

de las transacciones son fraude

Detectarlos sin generar alertas innecesarias.

Los datos



284.807
transacciones

492
fraudes

30
variables predictoras

Tras quitar 1.081 duplicados exactos: 283.726 filas y 473 fraudes; sin valores faltantes.

Preparación y partición

70/30
partición estratificada · semilla 42

5 pliegues
búsqueda sobre 50.000 filas fijas

85.118
filas de prueba reservadas

Limpieza ⟶ Entrenamiento ⟶ Validación ⟶ Prueba

El test no interviene en la selección; el ganador se reajusta con 198.608 filas.

Diseño experimental

Problema | Datos | Preparación | **Modelos** | Evaluación | Cierre

4 modelos × 2 condiciones

8 experimentos

k-NN | Árbol | SVM lineal | Bosque propio

Estándar
escalado para k-NN y SVM

ANOVA F
20 de 30 variables

1:10
submuestreo solo al entrenar

Bosque aleatorio propio

01
Bootstrap
Muestras con reemplazo

→

02
Árboles
$\sqrt{p}$ variables por división

→

03
Votación
Mayoría; empate = fraude

21 árboles · profundidad 6
Implementación del proyecto

Selección del modelo

Criterio: maximizar sensibilidad media en cinco pliegues.
Desempate: mayor precisión de fraude.

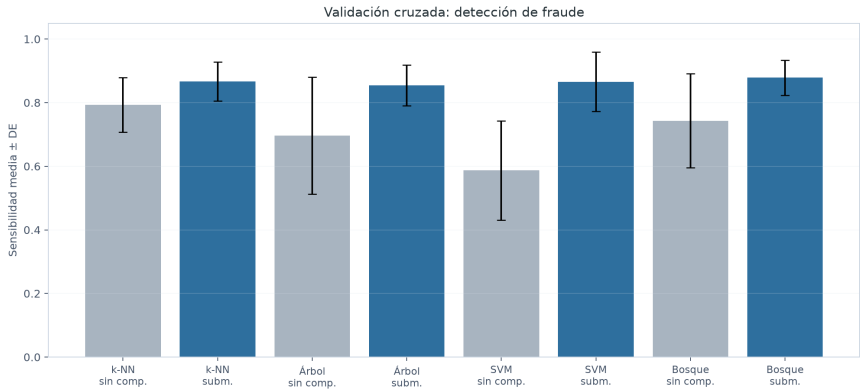
Bosque propio + submuestreo 1:10

87,9 % ± 5,5 %
sensibilidad en validación

45,0 %
precisión en validación

Validación cruzada

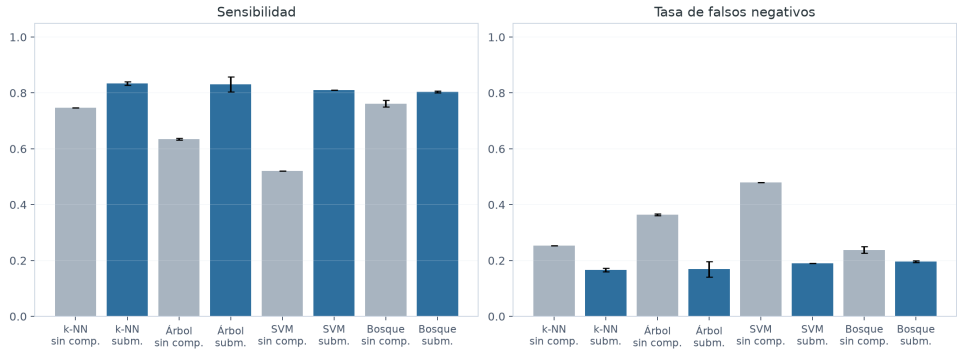
Problema | Datos | Preparación | Modelos | **Evaluación** | Cierre



Sensibilidad de fraude · cinco pliegues compartidos

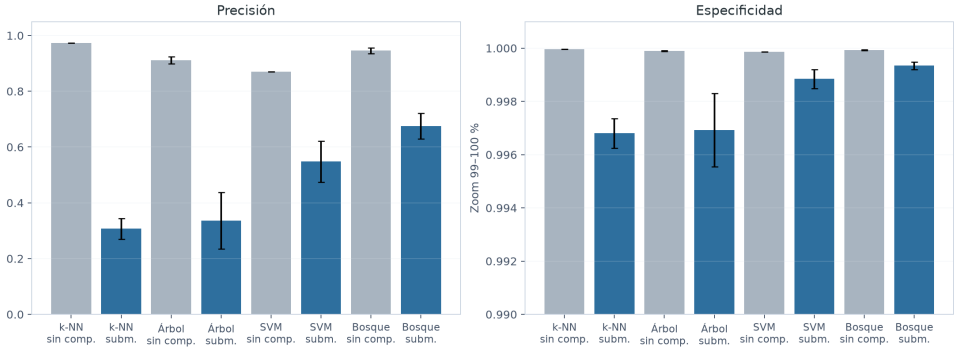
Prueba reservada

Problema Datos Preparación Modelos **Evaluación** Cierre



Mismo test fijo · media de cinco semillas

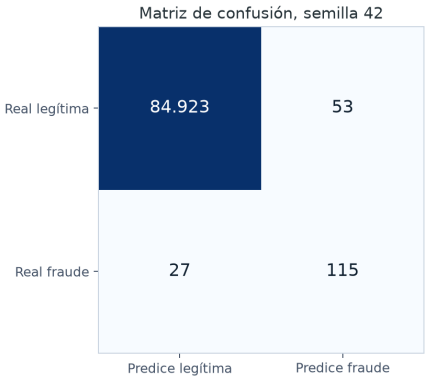
El costo de detectar más



Más sensibilidad también implica más falsas alarmas.

Casos del modelo elegido

Problema · Datos · Preparación · Modelos · **Evaluación** · Cierre



115
detectados

53
falsas alarmas

27
omitidos

84.923
legítimos reconocidos

Bosque con submuestreo · primer ajuste de prueba · semilla 42

Cierre

Problema | Datos | Preparación | Modelos | Evaluación | **Cierre**

80,4 %	19,6 %	67,5 %
sensibilidad	fraudes omitidos	precisión

El bosque compensado detecta 4 de cada 5 fraudes.

La exactitud sola engaña: predecir todo como legítimo da 99,833 % y sensibilidad 0 %.

El test contiene 142 fraudes; la estimación tiene incertidumbre.

Respaldo · Validación

Cinco pliegues compartidos sobre una submuestra fija de 50.000 filas.

Modelo	Condición	Mejores parámetros	Sensibilidad ± DE	Precisión
k-NN	Sin compensar	$k = 3$	79,3 % ± 8,6 %	91,2 %
k-NN	Submuestreo	$k = 3$	86,6 % ± 6,1 %	37,5 %
Árbol	Sin compensar	profundidad 5; hoja 5	69,6 % ± 18,4 %	79,8 %
Árbol	Submuestreo	profundidad 5; hoja 5	85,4 % ± 6,4 %	18,6 %
SVM lineal	Sin compensar	$C = 10$	58,7 % ± 15,6 %	88,5 %
SVM lineal	Submuestreo	$C = 10$	86,5 % ± 9,3 %	21,2 %
Bosque propio	Sin compensar	21 árboles; profundidad 12	74,3 % ± 14,7 %	91,6 %
Bosque propio	**Submuestreo**	**21 árboles; profundidad 6**	**87,9 % ± 5,5 %**	**45,0 %**

Respaldo · Métricas de prueba

Media ± desviación estándar en puntos porcentuales entre cinco semillas sobre el mismo test fijo.

Modelo	Condición	Sens.	Espec.	Prec.	F1	Exact.	FNR
k-NN	Sin comp.	74,6 ± 0,0	99,996 ± 0,000	97,2 ± 0,0	84,5 ± 0,0	99,95 ± 0,00	25,4 ± 0,0
k-NN	Subm.	83,4 ± 0,6	99,681 ± 0,056	30,7 ± 3,7	44,8 ± 3,9	99,65 ± 0,06	16,6 ± 0,6
Árbol	Sin comp.	63,5 ± 0,3	99,990 ± 0,002	91,1 ± 1,2	74,9 ± 0,4	99,93 ± 0,00	36,5 ± 0,3
Árbol	Subm.	83,1 ± 2,7	99,692 ± 0,138	33,6 ± 10,1	47,0 ± 9,6	99,66 ± 0,13	16,9 ± 2,7
SVM	Sin comp.	52,1 ± 0,0	99,987 ± 0,000	87,1 ± 0,0	65,2 ± 0,0	99,91 ± 0,00	47,9 ± 0,0
SVM	Subm.	81,0 ± 0,0	99,885 ± 0,036	54,8 ± 7,4	65,2 ± 5,4	99,85 ± 0,04	19,0 ± 0,0
Bosque	Sin comp.	76,2 ± 1,2	99,993 ± 0,002	94,6 ± 1,0	84,4 ± 0,6	99,95 ± 0,00	23,8 ± 1,2
Bosque	**Subm.**	**80,4 ± 0,3**	**99,935 ± 0,014**	**67,5 ± 4,6**	**73,3 ± 2,8**	**99,90 ± 0,01**	**19,6 ± 0,3**