Detectar fraude: minimizar lo que se pierde

Comparación de cuatro clasificadores, con y sin compensación del desbalance.

k-NN · Árbol de decisión · SVM · Random Forest propio

Prioridad: mayor sensibilidad. Desempate: mayor precisión del fraude.

Ocho experimentos, una partición compartida y evaluación reservada.

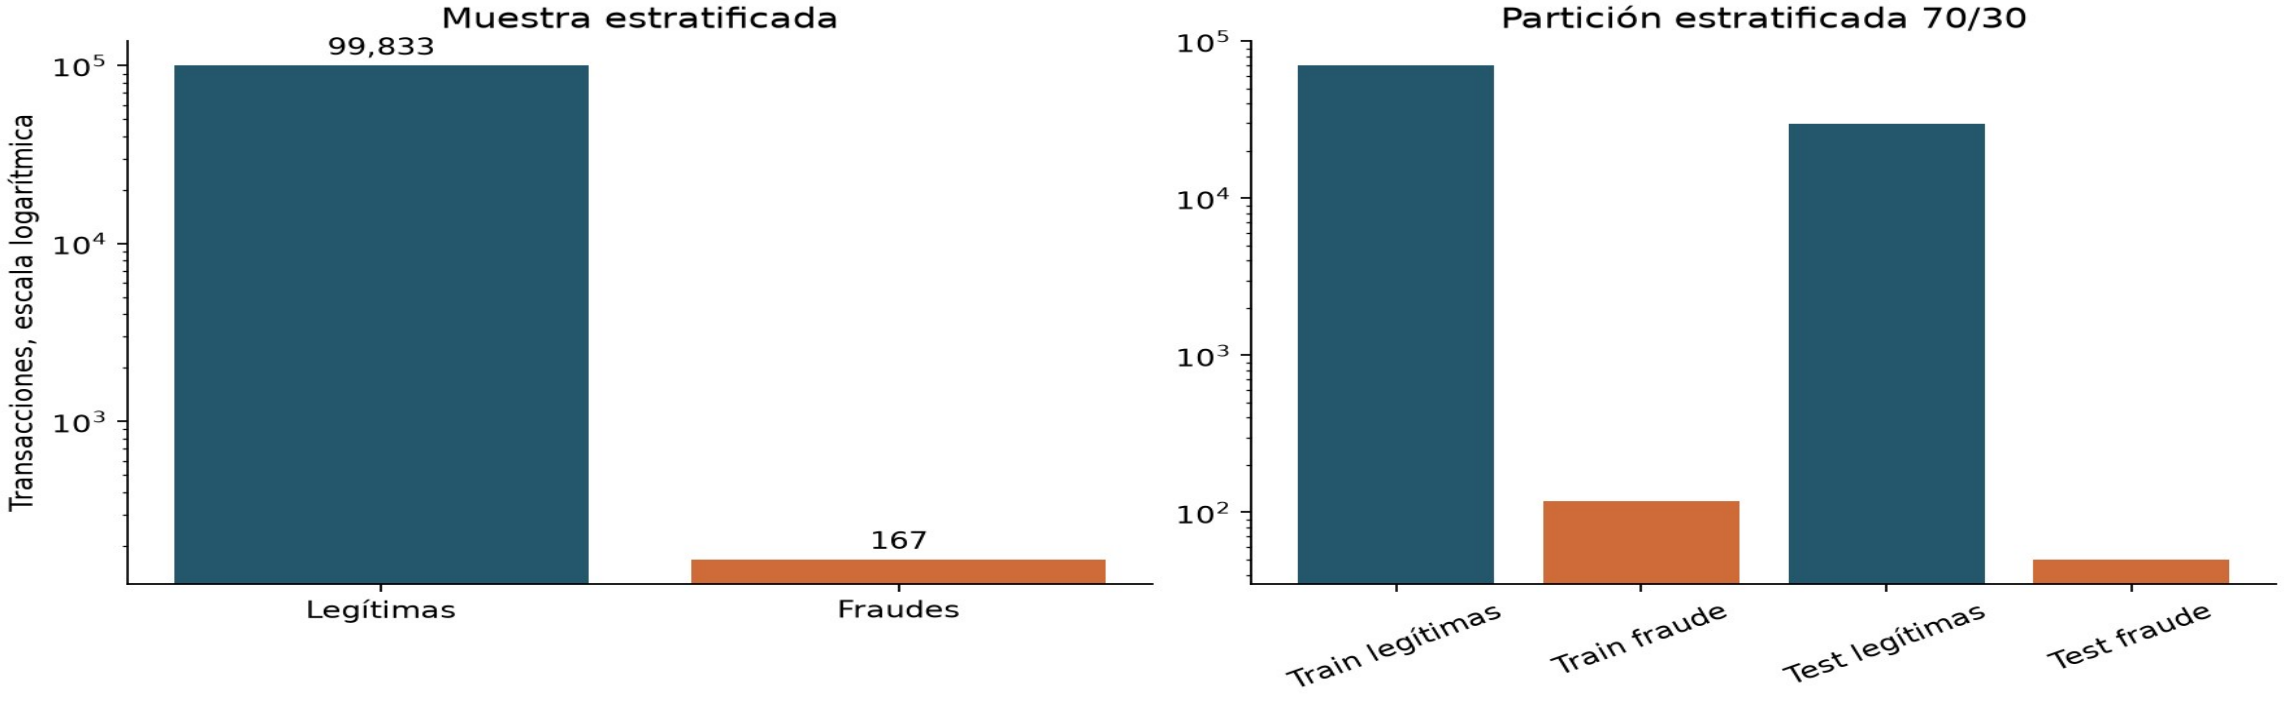
Fernando Alonso Valdés Gómez
Juan Francisco Muñoz Veloso

Pocos fraudes, muchas transacciones

284,807 filas originales → 283,726 únicas → 100,000 en la muestra.

Kaggle / copia TensorFlow. 30 predictores: Time, Amount, V1–V28. Class: 0 legítima, 1 fraude. Sin faltantes; 1,081 duplicados eliminados.

Original: 492 fraudes (0.173 %). Muestra: 167 (0.167 %), legítimas 99.833 %. Train/test: 117/50 fraudes.



El test se abre después de decidir

Partición estratificada 70/30, semilla 42; cinco pliegues idénticos en entrenamiento.

Entrenamiento → cinco pliegues → búsqueda → configuraciones congeladas

Dentro del pliegue: escalado → selección → compensación → clasificador

Reajuste completo → test fijo con tres semillas 42, 43 y 44

CV: desviación entre pliegues. Test: variación entre ajustes, ddof=1.

Seleccionar variables y compensar dentro del pliegue

20 de 30 predictores mediante ANOVA F. Class nunca se incluye en X.

k-NN y SVM se escalan por usar distancias; árboles no dependen de unidades.

ANOVA compara medias marginales; 20 variables acotan el costo. No se aplica otro PCA.

Selección supervisada antes del submuestreo, solo con el train del pliegue.

Con compensación: un fraude por diez transacciones legítimas.

Un bosque construido por la dupla

31 árboles: bootstrap con reemplazo, variables aleatorias y votación mayoritaria.

Por árbol: n filas con reemplazo y semilla propia → un DecisionTreeClassifier.

En cada división: considerar sqrt del número de variables disponibles.

Predicción final: mayoría de etiquetas; 31 árboles evita empates.

Configurables: árboles, profundidad, max_features, hoja mínima y semilla.

Bagging combina modelos entrenados en bootstrap para reducir variación; max_features busca reducir la correlación entre árboles.

Espacios de búsqueda fijados antes de evaluar

Misma grilla con y sin compensación. Dos candidatos por modelo; 80 ajustes de CV.

Modelo	Candidatos	Parámetros fijos y motivo
k-NN	Vecinos: 3, 7	Distancia euclídea; comparar vecindad pequeña y mayor.
Árbol	Profundidad: 6, libre	Hoja mínima 2; complejidad acotada y libre.
SVM	C: 1, 10	RBF, gamma=scale; regularización moderada y menor.
Bosque propio	Profundidad: 8, libre	31 árboles, sqrt, hoja mínima 2; diversidad y costo.

Prioridad: sensibilidad media. Empate exacto: precisión media; si persiste, primer candidato de la grilla.

Búsqueda acotada, selección por sensibilidad

Dos candidatos por modelo × cinco pliegues × ocho condiciones = 80 ajustes de CV.

Experimento	Parámetro elegido	Sensibilidad %
k-NN · sin compensación	n_neighbors=7	76.01 ± 6.62
k-NN · con compensación	n_neighbors=3	82.90 ± 2.77
Árbol · sin compensación	max_depth=6	69.28 ± 3.74
Árbol · con compensación	max_depth=None	87.14 ± 2.87
SVM · sin compensación	C=10.0	41.05 ± 9.44
SVM · con compensación	C=10.0	83.73 ± 3.35
Bosque propio · sin compensación	max_depth=None	71.01 ± 6.55
Bosque propio · con compensación	max_depth=8	82.90 ± 2.77

Prueba: detectar fraude y controlar las alertas

Porcentajes: media ± desviación de tres ajustes sobre el mismo test.

Experimento	Sensibilidad	Especificidad	Precisión
k-NN · sin compensación	62.00 ± 0.00	99.99 ± 0.00	88.57 ± 0.00
k-NN · con compensación	80.67 ± 1.15	99.57 ± 0.13	24.73 ± 6.45
Árbol · sin compensación	66.00 ± 2.00	99.98 ± 0.01	82.60 ± 3.71
Árbol · con compensación	75.33 ± 4.62	98.33 ± 0.14	7.02 ± 0.55
SVM · sin compensación	66.00 ± 0.00	99.99 ± 0.00	94.29 ± 0.00
SVM · con compensación	82.00 ± 0.00	99.58 ± 0.01	24.51 ± 0.45
Bosque propio · sin compensación	64.67 ± 3.06	99.99 ± 0.00	93.25 ± 1.80
Bosque propio · con compensación	80.67 ± 2.31	99.91 ± 0.03	60.42 ± 8.07

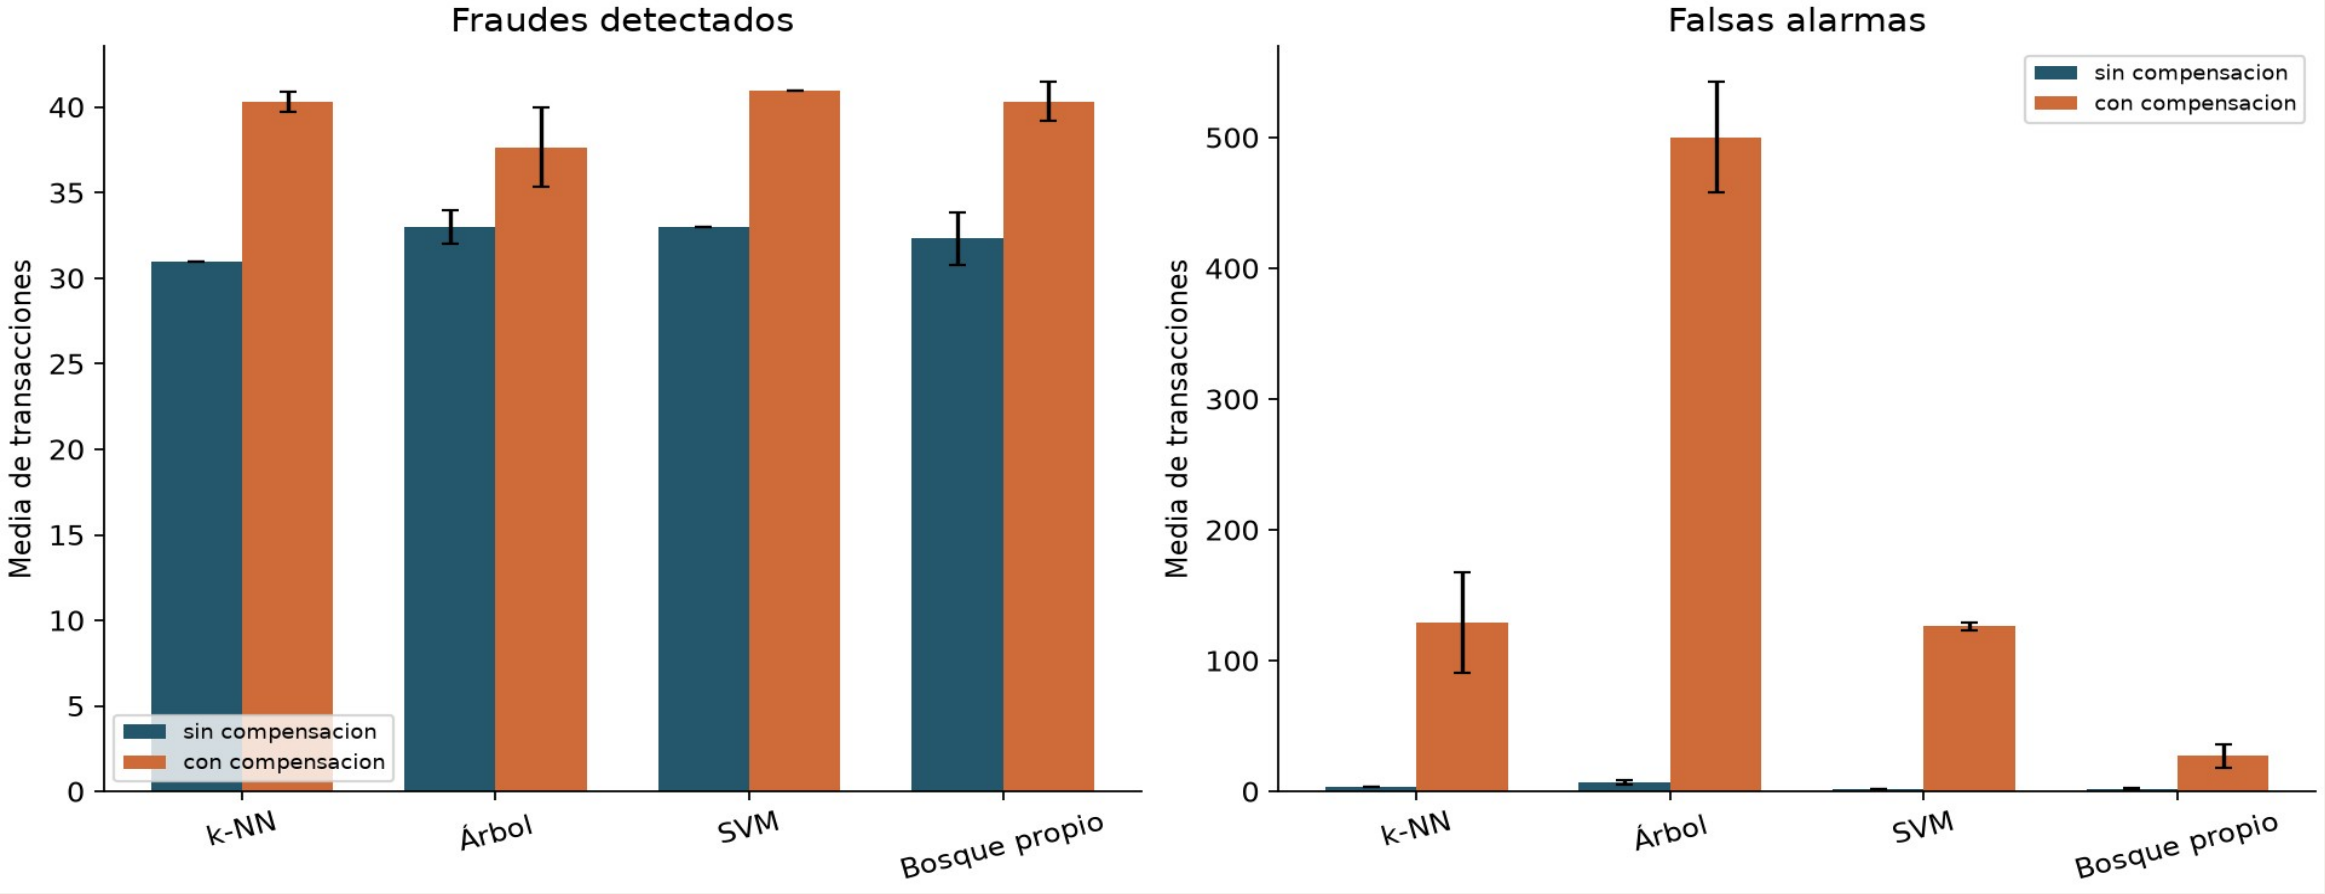
Prueba: F1, exactitud y falsos negativos

Porcentajes: media ± desviación de tres ajustes sobre el mismo test.

Experimento	F1	Exactitud	Tasa FN
k-NN · sin compensación	72.94 ± 0.00	99.92 ± 0.00	38.00 ± 0.00
k-NN · con compensación	37.58 ± 7.52	99.54 ± 0.13	19.33 ± 1.15
Árbol · sin compensación	73.34 ± 2.01	99.92 ± 0.01	34.00 ± 2.00
Árbol · con compensación	12.84 ± 0.94	98.29 ± 0.14	24.67 ± 4.62
SVM · sin compensación	77.65 ± 0.00	99.94 ± 0.00	34.00 ± 0.00
SVM · con compensación	37.74 ± 0.53	99.55 ± 0.01	18.00 ± 0.00
Bosque propio · sin compensación	76.36 ± 2.63	99.93 ± 0.01	35.33 ± 3.06
Bosque propio · con compensación	68.80 ± 4.22	99.88 ± 0.03	19.33 ± 2.31

El costo de detectar más

Azul: sin compensación. Naranja: con compensación. Medias de tres ajustes.



Árbol frente a bosque; exactitud frente a sensibilidad

Combinar árboles no garantiza mejorar cada métrica en cada condición.

Sin compensación: bosque frente a árbol cambia la sensibilidad en -1.33 puntos porcentuales y las falsas alarmas en -4.67.

Con compensación: bosque frente a árbol cambia la sensibilidad en +5.33 puntos porcentuales y las falsas alarmas en -473.00.

Siempre legítimo: exactitud 99.833 %, sensibilidad 0 %; 50 fraudes omitidos.

Siempre fraude: sensibilidad 100 %; 29,950 falsas alarmas.

Configuración elegida y límites de la evidencia

El ganador se eligió por validación, antes de mirar los resultados de prueba.

Elegido por validación: Árbol · con compensación. Sensibilidad CV 87.14 ± 2.87 %; sensibilidad test 75.33 ± 4.62 %; precisión test 7.02 ± 0.55 %.

Solo 50 fraudes. La desviación entre ajustes no mide incertidumbre sobre nuevas muestras.

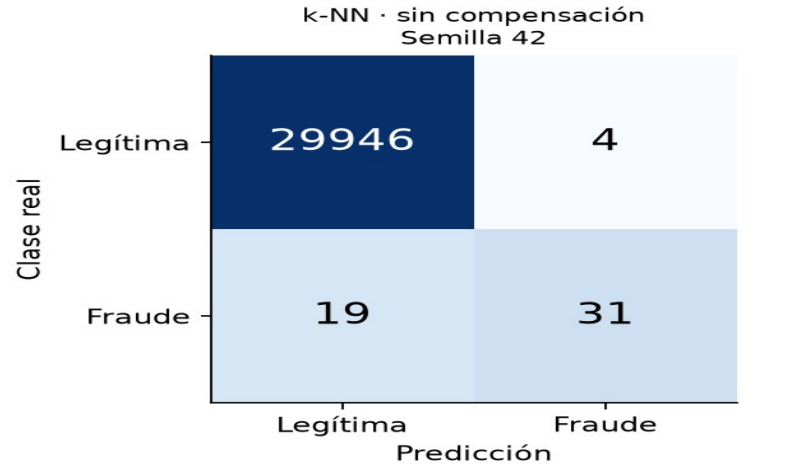
Muestreo y submuestreo pierden información; ANOVA es marginal y la grilla es pequeña.

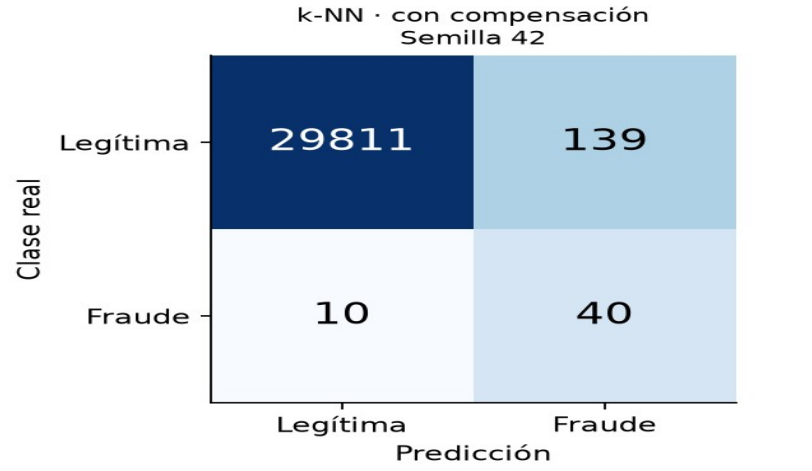
La división aleatoria no valida cambios temporales ni generalización a otros bancos.

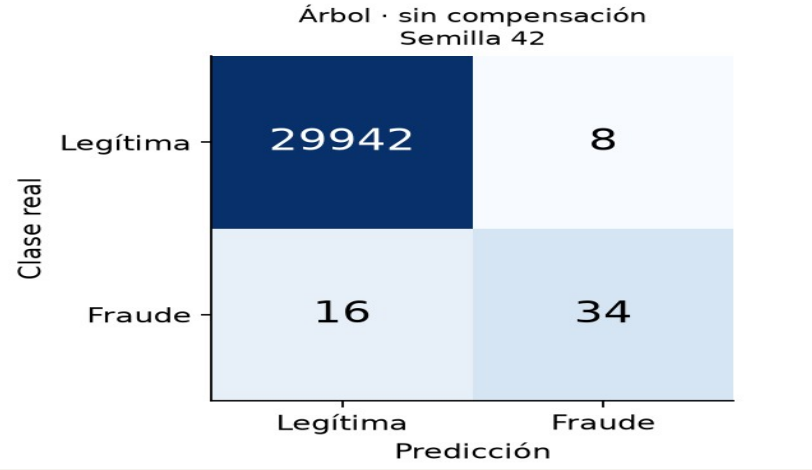
Mejoras futuras: más fraudes, validación temporal y grillas más amplias. Requieren un nuevo protocolo y un test no utilizado.

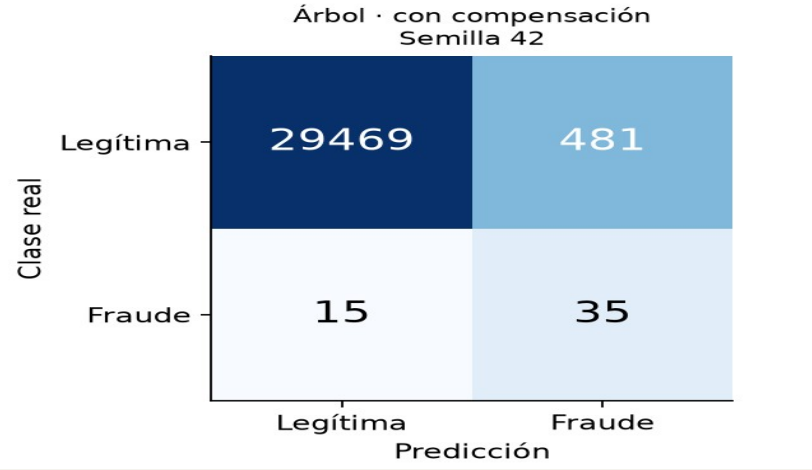
Respaldo: matrices de confusión

Semilla 42. Filas: clase real; columnas: predicción. Fraude es la clase positiva.



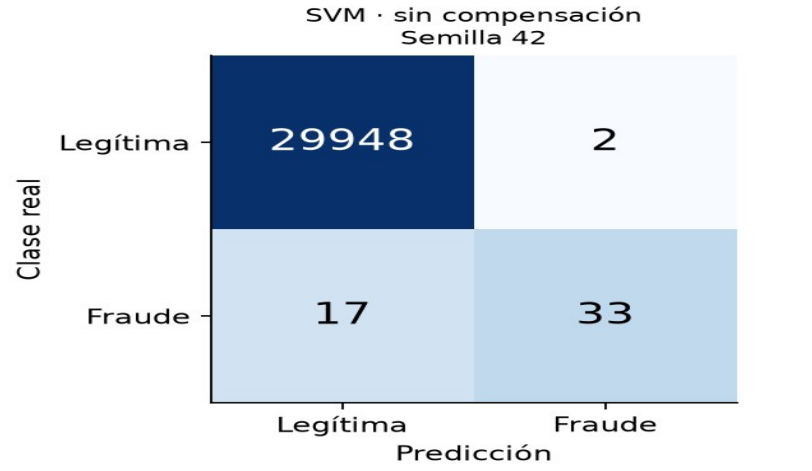


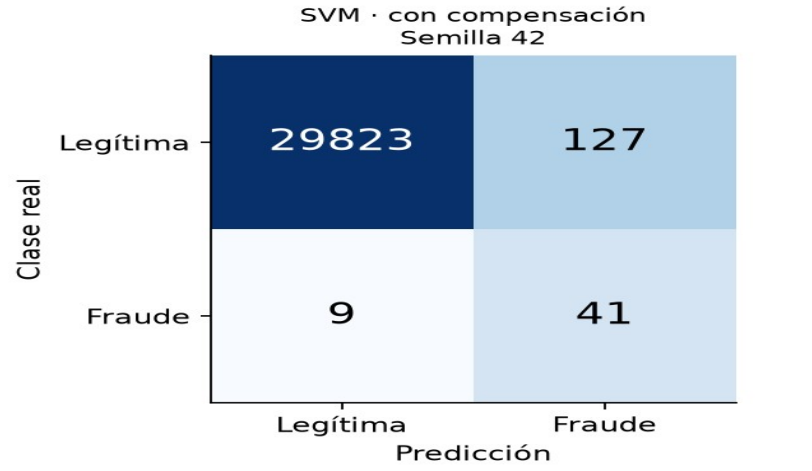


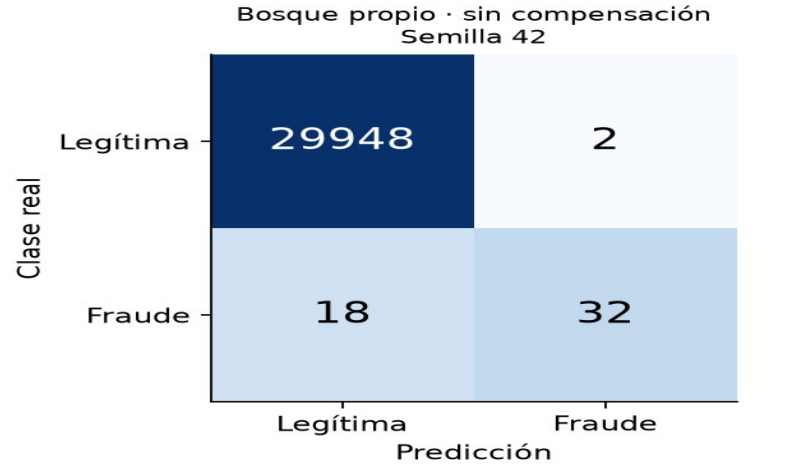


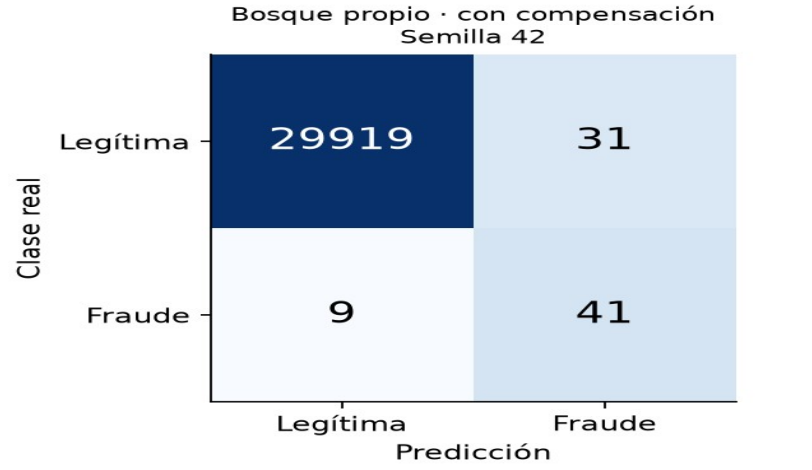
Respaldo: matrices de confusión

Semilla 42. Filas: clase real; columnas: predicción. Fraude es la clase positiva.









Respaldo: características y recuentos finales

Selección reajustada con todo el entrenamiento, semilla 42.

k-NN · sin compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 69883, '1': 117}.

k-NN · con compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 1170, '1': 117}.

Árbol · sin compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 69883, '1': 117}.

Árbol · con compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 1170, '1': 117}.

Respaldo: características y recuentos finales

Selección reajustada con todo el entrenamiento, semilla 42.

SVM · sin compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 69883, '1': 117}.

SVM · con compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 1170, '1': 117}.

Bosque propio · sin compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 69883, '1': 117}.

Bosque propio · con compensación: V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V14, V16, V17, V18, V19, V20, V21, V27
Train antes {'0': 69883, '1': 117}; después {'0': 1170, '1': 117}.